

面向智能体的大模型自进化强化学习系统

孙豪

中国人民大学 智慧治理学院

摘要

摘要 大语言模型驱动的智能体在代码沙箱、文件系统等真实环境中通过多步工具调用完成任务，强化学习是让其持续变强的主流手段。然而，交互式智能体的强化学习面临一个根本性瓶颈：训练数据与可信奖励均难以靠人工规模化获得——真实用户数据积累慢、覆盖窄，而奖励若仅依赖智能体自述，模型会迅速习得谎报完成这一奖励作弊行为。本文提出一套面向智能体的自进化强化学习系统，使智能体在无人工标注条件下自主产生训练数据、自主获得可信奖励、自主生成下一轮训练任务。系统包含四个核心机制：（1）由三智能体协作与沙箱状态真继承驱动的跨步自进化任务生成；（2）将打分锚定在确定性环境状态差分而非自述的差分驱动奖励；（3）每步只保留梯度最优轨迹子集的超采样-淘汰-选组；（4）失败案例驱动的评估器与基建自演化。系统在 Qwen3.5-9B 上端到端验证，完整链路仅由少量种子驱动、除初始种子外不依赖任何外部数据；离线评测进一步确认训练带来的是相对未训练基座的真实能力提升，而非仅训练指标好看。

关键词 大语言模型智能体；强化学习；自进化；奖励作弊；GRPO

1 引言

随着大语言模型能力与应用场景不断扩展，依赖人工构造任务和固定数据集的传统训练范式面临扩展瓶颈：固定数据难以覆盖不断增长的任务空间，而交互式智能体的强化学习持续消耗新的交互轨迹，使数据获取成为限制训练规模与持续迭代的关键因素。自进化正是对此的回应——使模型在极少人工干预下，通过“生成—执行—评估—反馈—更新”的循环不断产生新经验并优化自身 [1, 2]。

自进化在两个层面展开。在**模型层面**，模型自行生成数据、自我评分、筛选后微调自身，衍生出自我博弈、自我奖励、RLAIF、拒绝采样、进化搜索等范式 [3, 4, 5, 6]；在**智能体层面**，智能体在环境中积累经验，持续改进记忆、技能库、工具使用、提示词与规划策略，乃至底层模型参数。本文系统同时贯通二者：既让模型自主生成数据、以环境真实状态为准自我评分、经强化学习更新参数，又让智能体在沙箱中积累经验、以失败案例驱动评估提示词与工具/基建的持续演化。

然而，当任务生成、奖励评估与策略更新均由系统自动完成时，训练闭环也面临新的风险：评估偏差或低质数据会随后续轮次被放大 [7, 8]——智能体可能通过迎合评估器偏好获得高分而实际未完成任务。因此，自进化系统不仅需要持续产生数据，还需建立与环境执行结果相结合的奖励评估，并对候选经验进

行质量控制。本文的主要贡献为：

- **跨步自进化任务生成**：让每个新任务生长在上一轮真实产物之上，除初始种子外自主产生所有后续任务。
- **多智能体自主数据生成**：使采样、取证、追问全部自主化。
- **差分驱动奖励**：将打分锚定在确定性环境状态差分，从取证机制上抑制奖励作弊。
- **失败案例驱动的评估器与基建自演化**：将自进化从任务与策略扩展到评估器与基建四维。
- 在 Qwen3.5-9B 上的**端到端验证**：闭环可自我维持并带来真实能力提升。

2 系统概述

系统由三个协同智能体（执行者、观察者、提问者）、代码沙箱、外部冻结裁判 [15] 与 GRPO 训练器 [9] 组成。执行者以 ReAct 方式推理与行动 [10]，并以可执行代码为动作空间 [11]。全部自定义采样与选组逻辑通过强化学习框架的官方注入点接入，与框架主体解耦。总体架构如图 1 所示。

将自进化过程建模为转移算子 $\mathcal{T}$ 在系统状态 $\sigma_t = (\theta_t, s_t, Q_t, \Phi_t)$ （策略参数、沙箱状态、任务集、




图 1: 系统总体架构: 三协同智能体、代码沙箱、冻结裁判与 GRPO 训练器, 经框架注入点接入。

评估器/基建状态) 上的反复作用。一个训练步内主循环分三个阶段:

$$Q_t \xrightarrow{\pi_{\theta_t}} \tau_t \xrightarrow{\text{Observer}} d_t, \quad (1)$$

$$d_t \xrightarrow{\text{Judge}(\cdot; \Phi_t)} R_t \xrightarrow{\text{GRPO}} \theta_{t+1}, \quad (2)$$

$$(\tau_t, d_t) \xrightarrow{\text{Questioner}} Q_{t+1}. \quad (3)$$

主循环之外, 评估器/基建状态 Φ_t 由失败案例集 $\mathcal{B}_t$ 驱动、按低频演化。传统强化学习是其退化情形 ($Q_t \equiv Q_0$ 、 $s_t \equiv s_0$ 、 $\Phi_t \equiv \Phi_0$, 仅 θ_t 演化); 本文系统同时演化四个维度。

3 方法

3.1 跨步自进化任务生成

本机制使系统除初始种子外自主产生所有后续任务, 核心是让下一轮任务生长在上一轮真实执行结果之上。每步结束后, 对每个存活组取奖励最高的轨迹及其沙箱状态; 观察者视随机策略概括该轨迹的“意图—产物—缺口”; 沙箱文件系统状态被真继承到新沙箱 (真状态继承而非文本描述); 人设驱动的提问者据此生成下一轮种子。闭环如图 2 所示。

执行概括设为随机启用, 由此产生两种互补任务模式: 延续模式 (启用概括) 把已有工作延伸成长程任务链, 新任务模式 (不启用) 仅面对继承环境提出全新任务。以概括替代原始轨迹是有意的——将旧策略轨迹原文拼入新策略上下文会引入离策略偏差与分布偏移, 而概括只保留剥离了旧策略生成痕迹的任务层信息。




图 2: 跨步自进化: 最优轨迹的沙箱状态被继承, 提问者基于执行概括生成下一轮任务。




图 3: 多智能体协作数据生成: 执行者、观察者、提问者串接在同一沙箱会话上。

3.2 多智能体自主数据生成

三个职责分离的智能体把一次采样变成完整的“提问—执行—取证”交互 (图 3)。**执行者** (被训练策略) 在沙箱中以 ReAct 求解任务; **观察者** 在执行前后各拍只读快照、作差得到确定性状态差分, 只依据环境证据而不采信自述; **提问者** 扮演人设驱动的模式用户生成下一轮种子。求解与追问是开放性生成, 取证要求客观不可操纵——这种“能力与确定性分离”正是差分驱动奖励可信的基础。训练数据由系统内各单元的相互博弈动态产生, 是一种以真实沙箱为环境、以环境状态而非纯文本为裁决依据的自我博弈。以角色分工的智能体生成交互数据的思路与 CAMEL [14] 及多角色自进化 (如 R-Zero [16]) 一脉相承。

3.3 超采样-淘汰-选组

为提升每步信号质量, 将推理与训练解耦。每步超采样 S 个种子 $\times n$ 条轨迹; 淘汰同时满足“最大奖

励处于后 20%”且“低于阈值”的组（至少保留 80%）；对存活的 R 组按组内优势绝对值均值排序，取前 N 组做 GRPO。这一“动态采样、过滤无效组”的思路与 DAPO [12] 一脉相承。依据在于：GRPO 梯度由组内优势驱动，零方差（全对/全错）组不贡献有效更新；在固定预算下选高信号子集可最大化每步策略改进。

3.4 差分驱动奖励

将打分的证据基准从“智能体说了什么”换成“环境里真实发生了什么”。冻结裁判依据观察者的确定性状态差分（文件系统与系统状态变更）打分，自述仅作交叉核对。评分采用多维度乘性聚合（完成度、正确性、轨迹质量），任一关键维为零则总分为零；安全维为二元门；空差分直接短路为 0、不调裁判。形式化地，对任何仅改变自述、不改变状态差分的行为 δ ($d(\delta) = d$)，有 $\mathbb{E}[R | \delta] = \mathbb{E}[R]$ ：纯话术作弊被完全阻断，任何奖励提升都必须以真实的环境改变为前提。

3.5 失败案例驱动的评估器与基建自演化

除任务与策略外，完整的自进化智能体还应演化其评估器（打分/提问提示词）与基建（工具、沙箱、执行环境）。已有工作表明失败可经语言化反思归因与修复 [18]、缺失能力可沉淀为可复用技能库 [17]。在此基础上，系统周期性收集失败案例（执行失败、奖励异常、自述与差分矛盾）；每 10 步或攒够 20 例，由大模型将根因归于模型侧（规划、工具使用、方案选择）或基建侧（缺依赖、缺工具、超时过短、harness 缺陷），据此分别对提示词做增量修订、或将缺失能力沉淀为可复用技能。

3.6 自进化稳定性控制

系统无人值守运行，在现有计算路径上监控五项坍缩指标：奖励标准差、优势标准差、策略 KL、训练损失 (NaN/Inf)、存活组数。任一触发即终止——各指标对应不同失稳模式，任一单独触发都意味继续运行只会浪费算力。

4 实验

4.1 设置

基座为 Qwen3.5-9B，采用标准 GRPO，推理与训练异步解耦。正式训练用 2 节点 $\times$ 8 卡 H800，每




图 4: 奖励均值随训练步变化 (EMA 平滑): 自产生数据 (本文) 与回流基线对比。

步 $N=64$ 组，运行 50 步（为与传统 RL 对比而手动结束；系统本身除稳定性判据外不限制步数）。下文结果均来自同一次端到端实验，只是从不同维度观察。

4.2 闭环自我维持与奖励

超采样量 S 单调收缩并稳定在 N 附近而不塌缩至零，各步跨步种子均成功生成——在无外部数据补给下闭环可自我维持。图 4 在完全相同的 GRPO 管线下对比自产生数据与回流基线的奖励均值：自产生数据从约 0.33 稳步升至约 0.55，走势贴合并略高于基线，其训练价值不弱于真实回流数据。

作为伴随信号，自产生数据的组内奖励标准差逐步缓慢收窄（轻微方差坍缩、Echo-Trap [13] 前兆），而基线保持平稳——自产生数据在轮次间逐渐趋同，回流数据则由外部持续注入多样性。

4.3 能力评测

过程指标无法单独证明能力真的提升：由于奖励口径本身随自进化演化，奖励升高可能只是系统把自己的评分刷高。为此，本文以独立于训练回路的离线评测（ClawEval 文本任务）为尺子，对比三个模型：未训练基座、回流数据训练模型、本文自进化训练模型。如图 5，本文模型得分 0.401，明显高于未训练基座 (0.370)；因评测独立于训练奖励，该提升反映的是真实的能力增益而非训练指标的虚高。生成多样性小幅下降 (0.285 对基座 0.294)，与训练中观测的方差坍缩一致——过程与终点指标彼此吻合。

5 结论

本文提出的自进化强化学习系统同时贯通模型层面与智能体层面，将自进化的对象从“策略”单维扩




图 5: 三个模型在通用任务上的平均得分；离线评测独立于训练奖励口径。

展到“任务、策略、评估器、基建”四维：系统自主产生数据、将奖励锚定在确定性环境状态差分、按梯度质量筛选轨迹、并以失败案例演化评估器与基建。在 Qwen3.5-9B 上端到端运行，少量种子即可驱动完整强化学习训练、除初始种子外不依赖外部数据，独立评测确认了相对未训练基座的真实能力提升。多模态扩展、多样性正则与更大规模的训练是自然的后续方向。

参考文献

- [1] Z. Tao 等, “A survey on self-evolution of large language models,” arXiv:2404.14387, 2024.
- [2] J. Huang 等, “Large language models can self-improve,” arXiv:2210.11610, 2022.
- [3] Z. Chen 等, “Self-play fine-tuning converts weak language models to strong language models,” arXiv:2401.01335, 2024.
- [4] W. Yuan 等, “Self-rewarding language models,” arXiv:2401.10020, 2024.
- [5] H. Lee 等, “RLAIF: Scaling RLHF with AI feedback,” arXiv:2309.00267, 2023.
- [6] A. Zhao 等, “Absolute Zero: Reinforced self-play reasoning with zero data,” arXiv:2505.03335, 2025.
- [7] J. Skalse 等, “Defining and characterizing reward hacking,” in NeurIPS, 2022.
- [8] L. Gao, J. Schulman, J. Hilton, “Scaling laws for reward model overoptimization,” arXiv:2210.10760, 2022.
- [9] Z. Shao 等, “DeepSeekMath,” arXiv:2402.03300, 2024.
- [10] S. Yao 等, “ReAct: Synergizing reasoning and acting in language models,” arXiv:2210.03629, 2022.
- [11] X. Wang 等, “Executable code actions elicit better LLM agents,” arXiv:2402.01030, 2024.
- [12] Q. Yu 等, “DAPO: An open-source LLM reinforcement learning system at scale,” arXiv:2503.14476, 2025.
- [13] Z. Wang 等, “RAGEN: Understanding self-evolution in LLM agents via multi-turn RL,” arXiv:2504.20073, 2025.
- [14] G. Li 等, “CAMEL: Communicative agents for ‘mind’ exploration of large language model society,” arXiv:2303.17760, 2023.
- [15] L. Zheng 等, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” arXiv:2306.05685, 2023.
- [16] C. Huang 等, “R-Zero: Self-evolving reasoning LLM from zero data,” arXiv:2508.05004, 2025.
- [17] G. Wang 等, “Voyager: An open-ended embodied agent with large language models,” arXiv:2305.16291, 2023.
- [18] N. Shinn 等, “Reflexion: Language agents with verbal reinforcement learning,” arXiv:2303.11366, 2023.