

中國人民大學

专业硕士学位论文

面向智能体的大模型自进化强化学习系统研
(中文题目) 究与实现

Research and Implementation of
a Self-Evolving Reinforcement
Learning System for Agentic

(英文题目) Large Language Models

作者学号: 2025104468

作者姓名: 孙豪

所在学院: 智慧治理学院

专业名称: 电子信息-人工智能

导师姓名: 卞昊穹 孙殿森
自进化强化学习; 多智能体合成

论文主题词: 数据; 差分驱动奖励

论文提交日期: 2027 年 04 月

独创性声明

本人郑重声明：所呈交的论文是我个人在导师的指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国人民大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者（签名）：_____ 日 期：_____

关于论文使用授权的说明

本人完全了解中国人民大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

论文作者（签名）：_____ 日 期：_____

指导老师（签名）：_____ 日 期：_____

授权书影印件

摘要

大语言模型驱动的智能体在代码沙箱、文件系统等真实环境中通过多步工具调用完成任务，强化学习是让其持续变强的主流手段。然而，交互式智能体的强化学习面临一个根本性瓶颈：**训练数据与可信奖励均难以靠人工规模化获得**。真实用户回流数据积累慢、覆盖窄；而奖励若仅依赖智能体自述，模型会迅速学会谎报完成这一奖励作弊行为。

本文设计并实现一套面向智能体的自进化强化学习系统，其核心是让智能体在无人工标注条件下**自主产生训练数据、自主获得可信奖励、自主生成下一轮训练任务**。系统以**自进化**为第一目标：除初始种子外，后续所有训练查询由系统基于上一轮执行经验自主生成——观察者用大模型概括上轮最优轨迹的执行情况，提问者据此生成符合人设的新种子，沙箱文件系统状态跨步继承到新环境，使智能体在上轮产出的基础上继续工作。超采样-淘汰-选组机制进一步保证每步训练只用梯度最优的轨迹子集，提升自进化效率。

在数据自主产生方面，三个协同智能体把一次采样变成一段自主交互经验：执行者在沙箱中以 **ReAct** 方式求解任务，观察者对沙箱前后状态作差得到确定性状态差分，提问者基于上轮经验生成下一轮种子。在奖励可信方面，外部冻结裁判依据环境真实状态差分而非智能体自述打分，从取证机制上抑制奖励作弊。此外，系统以**失败案例驱动评估器与基建的自演化**：周期性收集失败案例，由大模型区分其根因在模型还是基建，进而分别修正提示词或将缺失能力补齐为可复用技能，使自进化从任务与策略扩展到评估器与基建。

系统在 **Qwen3.5-9B** 上端到端验证，完整自进化链路跑通，沙箱状态跨步继承验证通过。结果表明，少量种子查询即可驱动完整强化学习训练，系统除初始种

子外不依赖任何外部数据。

关键词： 自进化强化学习；多智能体合成数据；差分驱动奖励

Abstract

Large language model agents accomplish tasks through multi-step tool use in real environments such as code sandboxes and file systems, where reinforcement learning has become the dominant approach for continuous improvement. However, RL for interactive agents faces a fundamental bottleneck: both training data and trustworthy rewards are difficult to obtain at scale through human effort. Real user data accumulates slowly with narrow coverage; and rewards that rely solely on agent self-reports lead to reward hacking, where the model learns to falsely claim task completion.

This thesis designs and implements a self-evolving RL system for agentic LLMs, whose primary objective is to enable agents to autonomously generate training data, obtain trustworthy rewards, and produce next-step training tasks without human annotation. The system takes self-evolution as its first goal: beyond the initial seed, all subsequent training queries are autonomously generated based on prior execution experience—an observer summarizes the previous step’s best trajectory, a questioner generates persona-consistent new seeds, and sandbox file-system state is inherited across steps so that the agent continues building on prior outputs. An oversample-eliminate-select mechanism further ensures that only the gradient-optimal trajectory subset is used for training at each step, improving self-evolution efficiency.

For autonomous data generation, three collaborative agents turn

each sampling into a self-driven interaction: an actor solves tasks via ReAct in a sandbox, an observer computes deterministic state diffs, and a questioner generates next-step seeds from prior experience. For reward trustworthiness, a frozen judge scores based on real environment state diffs rather than agent self-reports, suppressing reward hacking at the evidence level. In addition, the system drives self-evolution of the evaluator and infrastructure from failure cases: it periodically collects failure cases, uses an LLM to attribute the root cause to either the model or the infrastructure, and accordingly revises prompts or distills missing capabilities into reusable skills, extending self-evolution from tasks and policy to the evaluator and infrastructure.

The system is validated end-to-end on Qwen3.5-9B, with the full self-evolution pipeline operational and sandbox state inheritance verified. Results show that a small number of seed queries can drive complete RL training, and the system operates without external data beyond the initial seed.

Key Words : Self-Evolving Reinforcement Learning; Multi-Agent Synthetic Data; Diff-Driven Reward

目录

第 1 章 绪论	1
1.1 研究背景	1
1.2 研究问题	3
1.3 研究内容	4
1.4 主要贡献	4
1.5 论文组织结构	6
第 2 章 相关理论与研究现状	7
2.1 大语言模型智能体	7
2.2 智能体评测环境	8
2.3 智能体强化学习与 GRPO	8
2.4 自进化强化学习	9
2.5 奖励建模与奖励作弊	9
2.6 失败归因与评估器、基建的自演化	10
2.7 现有研究分析	11
2.8 本章小结	12
第 3 章 问题建模	13
3.1 研究目标	14

3.2 自进化过程的形式化定义	14
3.3 自进化强化学习过程定义	15
3.4 核心问题.	19
3.5 系统研究边界	19
3.6 本章小结.	21
第 4 章 自进化强化学习方法设计	23
4.1 方法总体框架	23
4.2 跨步自进化任务生成机制	25
4.3 多智能体协作机制.	29
4.4 超采样-淘汰-选组机制.	32
4.4.1 为何训练只需 N 组：理论分析.	34
4.5 差分驱动奖励机制.	36
4.6 失败案例驱动的评估器与基建自演化机制.	38
4.7 自进化稳定性控制机制	41
4.8 本章小结.	43
第 5 章 自进化强化学习系统设计与实现	45
5.1 系统总体架构	45
5.2 沙箱环境与状态管理.	47
5.3 跨步状态继承	48
5.4 采样与训练解耦	49
5.5 自进化数据处理流程.	49
5.6 失败案例驱动的评估器与基建自演化	50
5.7 训练监控与自动终止.	50

5.8 系统运行流程	51
5.9 本章小结.	54
第 6 章 实验与结果分析	55
6.1 实验设置.	55
6.2 自进化闭环与超采样收缩	59
6.3 自主数据生成与任务难度演化	61
6.4 训练过程：奖励变化与稳定性	62
6.5 模型能力评测	65
6.6 综合分析.	67
6.7 本章小结.	68
第 7 章 总结与展望.	69
7.1 工作总结.	69
7.2 主要贡献.	70
7.3 局限性	70
7.4 研究展望.	71
参考文献	73
附录 A 各智能体的初始系统提示词	79
A.1 执行者 (Actor)	79
A.2 观察者 (Observer)	80
A.3 提问者 (Questioner)	81
A.4 裁判 (Reward Judge)	83
A.5 失败案例归因 (Attribution)	85

致谢	87
--------------	----

图目录

图 3.1 每步同步更新的三类状态在训练轮次间的传递：策略、沙箱、任务	17
图 3.2 评估器与基建的分路演进	18
图 4.1 自进化强化学习方法总体框架	24
图 4.2 跨步自进化闭环	26
图 4.3 多智能体协作机制	30
图 4.4 超采样-淘汰-选组机制	32
图 4.5 差分驱动奖励	36
图 4.6 失败案例驱动的评估器与基建自演化流程	38
图 4.7 自进化稳定性控制：五项监控指标与自动终止判据	41
图 5.1 系统总体架构	46
图 5.2 沙箱环境与状态管理：执行前后快照作差得到确定性状态差分	47
图 5.3 沙箱状态继承机制	48
图 5.4 三智能体协作时序	53
图 5.5 执行者沙箱内 ReAct 循环	53
图 6.1 超采样量 S 随训练步收缩	60
图 6.2 任务难度随自进化演化	61
图 6.3 自产生数据（本文）与回流数据（对照）训练的奖励均值对比（EMA 平滑）	62

图 6.4 组内奖励标准差随训练步的变化 (EMA 平滑): 自产生数据逐步 收窄 (方差坍缩), 回流数据平稳	64
图 6.5 三个模型在通用任务上的平均得分	65
图 6.6 三个模型的生成多样性 (任意通过率 <code>any_pass_rate</code>)	66

表目录

表 3.1 核心符号表 13

表 5.1 自动终止判据的阈值取值（本文实验设定） 51

表 6.1 实验配置 56

第 1 章 绪论

1.1 研究背景

近年来，随着大规模预训练与后训练技术的持续发展，大语言模型（Large Language Model, LLM）在语言理解、文本生成、复杂推理和代码生成等任务中展现出较强的通用能力。与此同时，大语言模型的应用形态逐渐由面向单轮文本生成的模型向能够进行任务规划、调用外部工具并与环境持续交互的智能体（Agent）演进^[1, 2, 3]。与传统文本生成任务相比，智能体通常需要在动态环境中执行由多个步骤组成的复杂任务，其最终表现不仅取决于单次输出的正确性，还与任务规划、工具调用、环境状态变化以及多轮决策过程密切相关。因此，如何进一步提升大语言模型在复杂环境中的多步决策与任务完成能力，成为智能体研究中的重要问题。

强化学习（Reinforcement Learning, RL）通过智能体与环境之间的持续交互，根据任务执行过程中获得的奖励信号优化模型策略，为提升智能体的决策能力提供了重要技术路径。近年来，强化学习逐渐应用于大语言模型的复杂推理、代码执行和智能体任务训练^[4, 5, 6]。其中，以群组相对优势为核心的 Group Relative Policy Optimization (GRPO)^[7] 通过比较同一任务下多个采样结果的相对表现构造策略优化信号，在无需显式价值模型的情况下实现模型策略更新，为大语言模型强化学习提供了有效的训练范式。然而，将强化学习应用于智能体场景后，训练数据和奖励评估面临的问题更加突出：一方面，智能体强化学习通常需要大量具有一定复杂度和多样性的任务，而人工构造和标注此类任务的成本较高；另一方面，智能体任务的完成情况往往难以通过单一标准答案进行判断，需要综合工具调用记录、执行轨迹以及外部环境状态进行评估，仅依赖生成轨迹或智能体自反馈可能

导致奖励评估偏差。

随着大语言模型能力和应用场景不断扩展，传统依赖人工构造任务和固定数据集的训练范式面临进一步的扩展瓶颈。一方面，固定训练数据难以持续覆盖不断增长的任务空间；另一方面，智能体强化学习过程中需要持续产生新的交互轨迹和训练经验，使训练数据的获取成为限制训练规模和持续迭代能力的重要因素。在此背景下，大语言模型自进化（**Self-Evolution**）逐渐受到关注^[8, 9]。自进化的基本思想是使模型在较少人工干预的情况下，通过“生成—执行—评估—反馈—更新”的循环不断产生新的经验并优化自身能力。这一思想在两个层面上展开：在**模型层面**，表现为模型自行生成数据、自我评分并筛选后微调自身，衍生出自我博弈、自我奖励、RLAIF、拒绝采样、进化搜索等多种范式^[10, 11, 12, 13]；在**智能体层面**，则表现为智能体在环境中积累经验，持续改进其记忆、技能库、工具使用、提示词与规划策略，乃至更新底层模型参数。其中，自主产生训练数据是实现自进化的重要环节^[14, 13, 15]：模型可以利用已有任务和交互经验生成后续任务，并结合执行结果筛选具有训练价值的经验用于策略优化，从而降低对固定任务集合和持续人工数据采集的依赖。对于智能体强化学习而言，进一步利用环境状态及其变化，可以使任务生成、执行反馈和策略更新形成更加紧密的闭环，使训练过程由固定数据集驱动逐渐转变为由模型、任务和环境共同驱动的动态训练过程。本文所构建的系统正是同时贯通这两个层面：它既让模型自主生成数据、以环境为准自我评分、筛选后经强化学习更新自身参数，又让智能体在沙箱环境中积累经验、以失败案例驱动评估提示词与工具/基建的持续演化，从而在一个闭环内同时演化任务、策略、评估器与基建。

然而，当任务生成、奖励评估和策略更新均由系统自动完成时，训练闭环同时面临新的风险。如果奖励评估存在偏差，或者生成的数据质量不足，该偏差可能随着后续任务生成和策略更新被进一步放大^[16, 17]。例如，智能体可能通过生成符合评价器偏好的行为获得较高奖励，但实际环境状态并未达到任务要求；低质量或重复任务也可能在多轮任务生成过程中不断出现，使训练数据逐渐偏离预期目标。因此，自进化强化学习系统不仅需要具备持续产生训练数据的能力，还需要建立与环境执行结果相结合的奖励评估机制，并对候选训练经验进行质量控制，从而提高训练闭环的稳定性和有效性。

基于上述背景，本文围绕面向智能体的大模型自进化强化学习系统展开研究。本文以少量人工提供的初始任务作为种子，使智能体在沙箱环境中执行任务并获得交互轨迹与环境状态变化，在此基础上自主生成后续训练任务；同时，通过环境状态差异辅助奖励评估，并结合候选轨迹的超采样、质量淘汰与训练组选择，对进入策略优化阶段的训练经验进行筛选，最终利用强化学习更新模型策略，并将更新后的模型用于下一轮任务生成与执行。通过上述机制，构建从任务生成、环境交互、状态观测、奖励评估、经验筛选到策略更新的持续迭代闭环，探索减少人工任务构造依赖并利用环境交互信息持续产生训练数据的实现方法。

1.2 研究问题

基于上述研究背景，本文关注的核心问题是：

能否构建一种面向智能体的自进化强化学习系统，以少量人工提供的初始任务作为种子，使模型在训练过程中自主产生后续训练任务与交互经验，并利用环境反馈构建奖励信号，通过有效的数据筛选与策略优化形成能够持续运行的自进化训练闭环？

围绕这一核心问题，本文进一步将研究内容分解为以下四个子问题：

子问题一（训练数据自主产生）：如何降低智能体强化学习对人工构造任务和外部真实数据的依赖，使系统能够利用已有任务与交互经验自主产生具有训练价值的后续任务？

子问题二（环境反馈与奖励评估）：如何利用交互过程中产生的客观环境状态变化辅助奖励评估，降低仅依赖智能体自述所带来的奖励误判，提高训练信号与实际任务完成情况的一致性？

子问题三（评估器与基建自进化）：在任务与策略之外，如何使评估器与执行基建也随训练持续改进——即根据失败案例在模型侧修正评估标准、在 **harness** 侧补齐缺失的环境能力，从而缓解奖励评估与执行环境的固有缺陷对训练闭环的制约？

子问题四（自进化闭环构建）：如何将任务生成、环境交互、奖励评估、经验筛选和策略更新组织为持续迭代的训练流程，使上一轮产生的经验驱动下一轮任务生成，并支持系统在预设终止条件下自主运行与监控？

1.3 研究内容

针对上述研究问题，本文设计并实现一套面向智能体的大模型自进化强化学习系统，主要研究内容包括：

（1）**自进化强化学习问题建模。**将传统“固定任务集—轨迹采样—奖励计算—策略更新”的强化学习训练流程扩展为“任务生成—环境交互—状态观测—奖励评估—经验筛选—策略更新—任务再生成”的闭环过程，并对系统中的任务状态、环境状态和策略状态进行形式化描述，为后续方法设计与系统实现提供统一的问题模型。

（2）**自进化强化学习方法设计。**针对训练任务自主产生、交互经验质量控制以及训练反馈可靠性等问题，设计跨步自进化任务生成、多智能体协作机制、超采样—淘汰—选组、差分驱动奖励、失败案例驱动的评估器与基建自演化以及自进化稳定性控制六个机制，使任务生成与模型训练能够在统一闭环中持续迭代。

（3）**自进化强化学习系统实现。**面向上述方法设计实现完整训练系统，包括沙箱环境、跨步状态继承、推理与训练异步调度、采样与训练解耦、数据与奖励处理、训练状态监控以及自动终止等工程模块，实现自进化强化学习流程的自动化运行。

（4）**实验验证与分析。**构建基础模型、传统强化学习训练流程及本文完整系统等对照实验，并针对任务生成、状态继承、奖励评估、候选数据筛选等关键机制开展消融实验，从任务生成质量、训练过程稳定性和独立测试任务上的模型能力等多个维度分析系统的有效性与适用范围。

1.4 主要贡献

本文围绕面向智能体的大模型自进化强化学习训练过程，主要贡献如下：

贡献一：提出跨步自进化任务生成机制。在单轮任务生成的基础上，将上一轮智能体执行产生的任务结果、环境状态及相关执行信息用于后续任务生成，使系统能够从少量初始种子出发持续产生后续训练任务，形成跨训练步骤的任务演化过程。

贡献二：提出多智能体协作机制。针对单个模型无法同时胜任求解、客观取证与模拟用户追问这三种性质迥异角色的问题，按“能力与确定性分离”的原则将其拆分为执行者、观察者与提问者三个协同智能体：执行者负责在沙箱中求解、提问者以人设驱动追加需求、观察者以环境证据客观取证。三者的分工与协作使训练任务、交互轨迹与环境反馈得以自主产生，且取证不受求解者操纵，为可信奖励提供客观基准。

贡献三：设计超采样—淘汰—选组的训练数据筛选机制。针对智能体强化学习中候选交互轨迹数量较多而有效训练样本有限的问题，通过增加候选轨迹数量，并依次进行低质量样本淘汰和训练组选择，在控制实际训练数据规模的同时提高候选训练经验的利用效率，实现“多推理、少训练”的数据筛选流程。

贡献四：设计差分驱动的奖励评估机制。针对仅依据智能体自述或生成轨迹进行奖励评估可能产生偏差的问题，引入沙箱环境状态差异作为奖励评估的辅助证据，将智能体行为与实际环境变化进行关联，以降低奖励评估对智能体自反馈的依赖，提高奖励信号的环境可验证性。

贡献五：提出失败案例驱动的评估器与基建自演化机制。在任务与策略之外，将评估器与基建也纳入自进化对象：训练过程中周期性收集失败案例，由大模型综合任务意图、执行轨迹与环境证据判断失败根因在模型还是基建，进而分别对评估提示词进行增量修订或将缺失的基建能力总结为可复用的技能予以补齐，使评估与执行环境随训练持续自我完善。

贡献六：提出自进化稳定性控制机制。针对任务生成、奖励评估与策略更新均由系统自动完成时训练闭环可能出现的偏差累积与状态漂移问题，围绕候选数据规模控制、奖励信号约束以及训练状态监控与自动终止等方面设计稳定性控制策略，抑制低质量任务和奖励偏差在多轮迭代中的放大，保障自进化训练过程在预设条件下的持续稳定运行。

1.5 论文组织结构

根据本文的研究内容和研究思路，全文共七章，各章节主要内容如下：

- 第一章为绪论，介绍本文的研究背景、研究问题、研究内容、主要贡献以及论文整体组织结构。
- 第二章为相关理论与研究现状，介绍大语言模型智能体、智能体评测环境、智能体强化学习与 GRPO、自进化学习、奖励建模与奖励作弊以及相关训练框架，并对现有研究进行分析。
- 第三章建立面向智能体的大模型自进化强化学习问题模型，对智能体与环境的交互过程、自进化过程中的系统状态、训练数据与奖励信号进行形式化描述，并明确本文研究的问题边界。
- 第四章为自进化强化学习方法设计，详细介绍跨步自进化任务生成、多智能体协作机制、超采样—淘汰—选组、差分驱动奖励、失败案例驱动的评估器与基建自演化以及自进化稳定性控制六个核心机制。
- 第五章为系统设计与实现，介绍系统总体架构、沙箱环境、状态继承、异步调度、采样与训练解耦、训练数据处理以及训练监控等模块，并给出系统整体运行流程。
- 第六章为实验与结果分析，通过基础模型与强化学习基线实验、关键机制消融实验以及完整系统实验，分析本文方法在任务自主生成、奖励评估、训练数据筛选、训练稳定性和模型能力提升等方面的表现。
- 第七章为总结与展望，总结本文的主要研究工作和实验结论，分析当前工作的局限性，并对未来可能的研究方向进行展望。

第 2 章 相关理论与研究现状

本章综述与本文直接相关的理论基础与研究现状。其中 2.1-2.2 介绍大语言模型智能体及其评测环境，作为全章的共性背景；自 2.3 起各节大体沿本文方法的脉络组织：智能体强化学习与 GRPO (2.3)、自进化强化学习 (2.4)、奖励建模与奖励作弊 (2.5)、失败归因与评估器/基建自演化 (2.6)，最后在此基础上分析现有研究的不足，明确本文的定位。

2.1 大语言模型智能体

大语言模型智能体在代码沙箱、终端、文件系统等真实环境中，通过“思考—调用工具—观察结果”的循环完成多步任务。**ReAct**^[1] 首先将推理与行动统一在语言模型的生成过程中，使模型能够以交错的思维链与工具调用求解多步问题，成为当前交互式智能体的基础范式。**Toolformer**^[2] 证明语言模型可以通过自监督方式学习何时、如何调用外部工具，将 API 调用内化为模型能力。在交互经验的组织层面，**Reflexion**^[18] 让智能体以语言化的自我反思积累经验并在后续尝试中改进；**Voyager**^[19] 在开放游戏环境中以自动课程驱动技能库的持续扩张，是“经验自主积累”的早期代表。**CodeAct**^[3] 进一步表明，以可执行代码作为统一动作空间比离散工具调用更精确、更可组合，本文的执行者即采用代码沙箱内的 **ReAct** 循环。多智能体协作方面，**CAMEL**^[20] 通过角色扮演的双智能体会话规模化地生成指令数据，验证了“以智能体对话产生训练数据”的可行性，这一思路与本文的提问者—执行者协作直接相通。

这类交互式智能体的能力提升，既依赖模型本身的推理能力，也依赖在真实环境中的大量交互经验。如何低成本地获得这些交互经验，是智能体训练的关键问

题。

2.2 智能体评测环境

智能体能力的度量依赖标准化的评测环境。本文的模型能力评测选用 **ClawEval**——一个面向自主智能体的评测集，其任务在真实代码沙箱中执行、以工具调用完成，并配有官方 **grader** 按多维 **rubric** 打分。相比以最终答案匹配为主的封闭式基准，**ClawEval** 的任务贴近本文以文本工具调用为主的训练设定：任务在沙箱内多步求解、评分锚定于真实执行结果，与本文训练所用的沙箱环境和差分驱动打分口径同构，因而可作为衡量训练前后模型能力变化的客观依据。本文取其纯文本类任务，并辅以少量自定义补充任务用于离线评测（详见第 6.5 节）。

2.3 智能体强化学习与 GRPO

强化学习通过交互轨迹上的奖励信号直接优化策略，是提升交互式智能体能力的主流手段。**PPO**^[21] 以裁剪目标函数实现稳定的策略梯度更新，是 **RLHF** 时代的默认算法，也是本文所用 **GRPO** 的基础。**GRPO**（**Group Relative Policy Optimization**）^[7] 对同一查询的一组 **rollout** 做组内奖励归一化来估计优势，省去了价值网络，是本文采用的策略优化算法。围绕 **GRPO** 的改进中，**DAPO**^[22] 通过解耦裁剪与动态采样在大规模训练中提升稳定性，其“动态采样、过滤无效组”的思路与本文的超采样-淘汰-选组一脉相承；理论工作^[23] 进一步揭示 **GRPO** 的方差缩减主要由每步有效 **rollout** 总数驱动，为本文通过扩大采样规模、再精选高信号组提供了直接的理论依据。此外，多轮训练中的策略多样性坍塌（**Echo Trap**）现象^[24]——策略逐渐丧失多样性、所有轨迹趋于一致，导致梯度信号消失、训练停滞——直接支撑了本文将稳定性监控作为自进化系统的核心组件。

在真实环境中的智能体强化学习已有一批标志性实践^[4, 5, 6]，验证了强化学习激发智能体推理与工具调用能力的有效性，但它们的任务供给依赖固定数据集或人工构建的环境内置信号，奖励依赖可验证规则或环境回报，尚未解决开放交互场景下数据与奖励的自主供给问题。

2.4 自进化强化学习

自进化的核心思想是让模型通过自身产生的经验持续优化，而非依赖固定的外部数据集。在文本推理层面，这一方向已有系统性积累：**Self-Improve**^[9] 以自一致性筛选自生成答案实现自我提升；**Self-Instruct**^[14] 与 **Evol-Instruct**^[25] 以自生成与演化指令扩充训练数据；**ReST**^[26] 迭代式地在自采样数据上训练；**SPIN**^[10] 将自我提升形式化为自我博弈。更进一步，**Self-Rewarding**^[11] 让模型自评偏好充当奖励信号；**SEAL**^[27] 让模型自行生成自我改写以更新自身；**Absolute Zero**^[13] 以“提案—求解”双角色自我博弈，在零外部数据下训练推理器；**R-Zero**^[15] 用导师—求解者—验证者三角角色从零数据自进化出推理模型，其多角色分工与本文的三智能体协作在结构上相近。**RFT** 的持续微调研究^[28] 还表明，强化学习式微调比监督微调更不易遗忘，为以强化学习驱动持续进化提供了动机。

在交互式智能体层面，自进化也开始被探索：**AgentGym**^[29] 让智能体在多环境中以指令进化持续提升能力；**WebRL**^[30] 为网页智能体构建自进化在线课程——从失败任务合成新指令并动态调整难度，是“任务自主生成驱动智能体训练”的代表性工作。自进化方向的综述^[8] 将这类系统归纳为“经验积累—自我反思—能力更新”的循环。总体而言，现有自进化工作在核心思想上与本文一致——基于历史经验自主产生新训练信号，但它们主要停留在**文本层面**：任务由语言模板演化生成，环境反馈以文本匹配或规则判分给出，未涉及交互式智能体的**环境状态**在训练轮次间的传递与继承。而后者恰是真实沙箱环境中自进化的关键——智能体在上轮产出的文件与配置上继续工作，任务与状态才能形成有意义的演化链。

本文的部分工作和思路则参考了以上的研究或工作，并在这些研究的基础上进行改进、整合并加以创新。

2.5 奖励建模与奖励作弊

奖励的可信性是强化学习的核心问题。**RLHF**^[31] 以人工偏好训练奖励模型，但奖励模型本身可能被策略过度优化——**Goodhart** 效应使得策略学会迎合代理奖励而非真正完成任务^[32, 17]。**Skalse** 等^[16] 对奖励作弊（reward hacking）给出了

形式化定义与刻画，指出其根源在于代理奖励与真实目标之间的对齐偏差。在可验证任务上，GSM8K 的验证器^[33]与过程奖励模型 PRM^[34]以最终答案或逐步判分提供确定性信号，此类基于规则或程序校验的奖励在数学、代码等**结果易于验证**的封闭任务上行之有效。面向开放任务，RLAIF^[12]与 LLM-as-a-judge^[35]将裁判推广到无标准答案的场景，生成式验证器^[36]进一步将奖励建模统一为下一个 token 预测；但近期研究亦警示了奖励信号的脆弱性：Spurious Rewards^[37]发现在部分基座上随机奖励也能产生与真实奖励相当的提升，说明奖励信号与能力提升之间的因果关系远比预期复杂。

对智能体强化学习而言，这一问题更为尖锐：其任务复杂、执行结果的正确性难以程序化校验，即便最终产物看似正确，也难以判断其是否出于可靠的求解过程。更关键的是，若裁判仅依据智能体自述的轨迹文本打分，模型会迅速学会在轨迹中谎报完成，而裁判无从核实。因此，如何使奖励锚定于**环境的真实状态**而非智能体的自我叙述，是开放交互场景下奖励可信化的核心问题，目前尚未被充分解决。本文以确定性状态差分作为取证依据、并在其上进行多维度评分的奖励机制，正是针对这一问题而设计。

2.6 失败归因与评估器、基建的自演化

除任务与策略外，评估器（打分与提问的提示词）与工具集/基建也是可被自主演化的对象，这一方向的研究可归纳为三条线索。其一，**失败归因与自我调试**：Reflexion^[18]让智能体以语言化反思定位失败原因并在后续尝试中修正；Self-Debug^[38]教会大模型通过阅读执行结果解释并调试自身生成的代码，说明大模型具备对失败案例做根因分析的能力。其二，**提示词自动优化**：APE^[39]将提示词搜索形式化为大模型驱动指令生成与筛选，达到人类水平的提示词工程；ProTeGi^[40]以自然语言“梯度”与束搜索迭代改写提示词，验证了提示词可依据失败样本被自动、增量地修订。其三，**工具与技能的自主创建**：Voyager^[19]在开放环境中将成功经验固化为可复用的技能库并持续扩充；CREATOR^[41]让大模型在缺乏现成工具时自行创建工具以解决问题；Toolformer^[2]则表明工具使用能力可被模型自监督地内化。这些工作分别证明了失败可被大模型归因、提示词可被自动优化、工

具/技能可被自主创建。

然而，现有工作大多在**推理或部署阶段**、针对单个任务孤立地进行反思、调试或工具创建，尚未将“失败归因—提示词/基建演化”整合进**强化学习训练闭环**，也很少区分失败的根因究竟在**模型**（策略的规划、工具使用、方案选择失误）还是在**基建**（沙箱、工具、执行环境的缺陷）——而这一区分恰恰决定了应当修正提示词还是扩展基建。本文正是针对这一空白，在训练过程中周期性收集失败案例，由大模型综合任务意图、轨迹与环境证据做出模型/基建的归因，进而分别演化评估器提示词或将缺失的基建能力总结为可复用的技能或扩展工具予以补齐，使评估器与基建随训练持续自我完善。

2.7 现有研究分析

综合上述方向，现有研究呈现如下格局：算法层面（PPO、GRPO 及其变体）已较成熟，大规模智能体强化学习实践已有充分验证；已有面向智能体的标准化评测环境（如本文采用的 ClawEval）可作为模型训练的重要验收标准；自进化方向已有文本层面的系统探索（Self-Instruct、SPIN、Absolute Zero、R-Zero），并开始进入智能体场景（AgentGym、WebRL）；奖励建模已有 RLHF/RLAIF/裁判方案与作弊理论刻画；工程层面已有成熟的训练框架。然而，将这些要素整合为一套“自主、可信地供给训练数据与奖励，并持续自进化运转”的完整系统，仍存在巨大的研究潜力：

（1）数据供给仍依赖人工采集或固定数据集，缺乏交互式智能体在真实沙箱环境中的自主数据产生机制；

（2）奖励仍主要基于智能体自述文本或可验证规则，缺乏锚定环境真实状态的取证机制，难以在开放任务上同时兼顾覆盖面与抗作弊性；

（3）现有训练框架（如 verl^[42]、OpenRLHF^[43]、AReal^[44] 等）解决的是“如何高效训练”，提供的是通用的采样—更新工程底座，并不包含数据自主产生、奖励可信取证、跨步状态继承、失败归因与系统基建的自我完善等自进化所需的机制；换言之，尚缺少一套将上述环节串接为完整闭环、支撑自进化全流程端到端运转的系统。

(4) 失败归因与提示词/工具自演化虽已有研究，但多在部署阶段针对单任务孤立进行，未整合进训练闭环，也很少区分失败根因在模型还是基建，缺乏据此分别演化评估器提示词或补齐基建能力的机制。

本文正是面向上述空白，在通用训练框架之上自行设计并集成各自进化机制，将多智能体协作合成数据、差分驱动奖励、跨步自进化闭环（含沙箱状态继承与稳定性监控）、以及失败案例驱动的评估器与基建自演化串接为一套端到端运转的完整自进化强化学习系统。

2.8 本章小结

本章综述了大语言模型智能体与评测环境、智能体强化学习与 GRPO、自进化学习、奖励建模与奖励作弊、失败归因与评估器/基建自演化等方向的理论基础与研究现状，并分析指出：现有工作在算法与工程层面已较成熟，但在“如何自主、可信地供给训练数据与奖励，并使系统在真实环境中持续自进化运转”这一系统与数据层面仍有明显空白。本文的工作正是面向这一空白展开。

第 3 章 问题建模

本章建立面向智能体的自进化强化学习问题模型：先给出研究目标，再以转移算子形式化描述自进化过程、并逐阶段展开主循环，最后界定核心问题与系统研究边界。为便于全章引用，先汇总本章使用的核心符号，如表 3.1 所示。

表 3.1 核心符号表

符号	含义
t	训练步计数，每个训练步递增 1
t'	评估器与基建的演化周期计数，按低频触发递增 ($t' \leq t$)
Q_t	第 t 步的任务集； Q_0 为少量人工种子
π_{θ_t}	第 t 步被训练的策略，参数为 θ_t
τ_t	策略在沙箱中对 Q_t 执行产生的交互轨迹集
s_t	沙箱状态（工作区文件系统等）
d_t	观察者对执行前后状态作差得到的确定性状态差分
R_t	裁判在 Φ_t 下依据 d_t 给出的奖励
Φ_t	评估器与基建状态（各智能体提示词 + 工具/沙箱能力）； Φ_0 为人工初始配置
$\mathcal{B}_{t'}$	第 t' 个周期累积的失败案例集
$\Delta_{t'}$	归因产出的评估器/基建增量
$\hat{A}_{ij}$	第 i 组第 j 条轨迹的组内优势
N, n, S, R	训练组数、GRPO 组大小、超采样量、淘汰后存活组数

3.1 研究目标

本文的研究目标是构建一套自进化强化学习系统，使交互式智能体在无人工标注条件下满足以下四个目标：

目标一：数据自主产生。训练数据的获取基于交互生成——模型在与环境的交互（沙箱内工具调用）以及智能体间的协作（提问者追问、观察者取证）中动态产生新的经验与数据，而非依赖真实用户回流或人工采集。除少量初始种子用于冷启动外，后续训练数据由系统在交互过程中持续自主合成。

目标二：奖励可信。奖励锚定在环境真实状态而非智能体自述，从取证机制上抑制奖励作弊。

目标三：评估器与基建自演化。系统不仅演化任务与策略，还应将**评估器**（各智能体的提示词）与**基建**（工具集、沙箱、执行环境等）纳入自进化对象，为策略更新提供更可靠的奖励信号与更完善的运行环境。

目标四：自进化闭环。将上述数据产生、奖励评估、策略更新与评估器/基建自演化的过程组织为持续闭环，使系统在预设终止条件下长时间自主运转、无需人工干预，并在坍塌或崩溃时被及时监控与终止。

3.2 自进化过程的形式化定义

传统强化学习在固定任务集上采样、打分、更新策略，任务集由外部供给且训练过程中保持不变。本文将其扩展为一个自进化过程：任务本身由系统基于上一轮经验动态生成。本节先以一个作用于系统状态的**转移算子**给出该过程的整体形式化，下一节再逐阶段展开其内部结构。

定义 3.1 (自进化系统状态与转移算子). 记第 t 步的系统状态为四元组

$$\sigma_t = (\theta_t, s_t, Q_t, \Phi_t), \quad (3.1)$$

分别为策略参数、沙箱状态、任务集与评估器/基建状态。一个训练步的演化定义

为算子 $\mathcal{T}$:

$$\sigma_{t+1} = \mathcal{T}(\sigma_t) = (\underbrace{\text{GRPO}(\theta_t, R_t)}_{\text{策略}}, \underbrace{\text{Inherit}(\tau_t)}_{\text{沙箱}}, \underbrace{\text{Questioner}(\tau_t, d_t)}_{\text{任务}}, \underbrace{\Phi_t \oplus \Delta_{t'}}_{\text{评估器/基建}}), \quad (3.2)$$

其中 $\tau_t \sim \pi_{\theta_t}(Q_t)$ 、 $d_t = \text{Observer}(\tau_t)$ 、 $R_t = \text{Judge}(d_t; \Phi_t)$ ， $\Delta_{t'}$ 项仅在触发时非空。自进化过程即状态序列 $\{\sigma_t\}_{t \geq 0}$ 在 $\mathcal{T}$ 反复作用下的轨道。

传统强化学习是 $\mathcal{T}$ 的退化情形：任务集 Q 、沙箱 s 与评估器/基建 Φ 均由外部初始给定、训练全程固定不变，仅策略 θ_t 随训练演化；本文的自进化则让四个分量同时演化，因而 $\mathcal{T}$ 是一个任务分布随策略移动的非平稳算子。算子 $\mathcal{T}$ 的各分量如何由一个训练步内的采样、取证、评估、再生成具体产生，在下一节按阶段展开。

3.3 自进化强化学习过程定义

本节把上一节的转移算子 $\mathcal{T}$ 展开为一个训练步内的具体流程。任务与策略的主循环可分解为三个阶段，依次形式化如下。

阶段一：采样与取证。策略 π_{θ_t} 在沙箱中对任务集 Q_t 执行、产生交互轨迹集 τ_t ，观察者对每条轨迹执行前后的沙箱状态作差，得到确定性状态差分 d_t ：

$$Q_t \xrightarrow{\pi_{\theta_t}} \tau_t \xrightarrow{\text{Observer}} d_t \quad (3.3)$$

该阶段刻画“任务如何变成可评估的证据”： Q_t 经当前策略转化为真实的环境交互 τ_t ，再由观察者提炼为客观、不可被策略操纵的状态差分 d_t ，为后续奖励评估提供锚定在环境真实变化上的依据。

阶段二：奖励评估与策略更新。外部冻结裁判在当前评估器与基建状态 Φ_t 下依据 d_t 给出奖励 R_t ，再由 GRPO 据此更新策略参数：

$$d_t \xrightarrow{\text{Judge}(\cdot; \Phi_t)} R_t \xrightarrow{\text{GRPO}} \theta_{t+1} \quad (3.4)$$

该阶段刻画“证据如何转化为策略改进”：奖励以状态差分为输入、以 Φ_t 为评分口径，使奖励信号可验证且抗作弊；GRPO 据组内相对优势更新参数，得到改进后的策略 θ_{t+1} 。

阶段三：任务再生成。提问者基于本轮执行经验与沙箱状态，为下一轮生成新的任务集：

$$(\tau_t, d_t) \xrightarrow{\text{Questioner}} Q_{t+1} \quad (3.5)$$

该阶段是本文区别于传统强化学习的关键：下一轮任务 Q_{t+1} 不再由外部供给，而是由系统依据上一轮的真实执行与环境状态自主再生成，从而让任务随策略能力持续演化、闭环得以自我延续。三阶段首尾相接、由阶段三产出的 Q_{t+1} 回到阶段一，构成任务与策略在训练步间的协同演化，下标 t 逐步递增。

在上述主循环之外，本文进一步将**评估器与基建**纳入自进化对象。评估器与基建状态 Φ_t （包含各智能体的提示词与工具/沙箱等基建能力）在阶段二中作为裁判的评分口径出现（ $R_t = \text{Judge}(d_t; \Phi_t)$ ）。与策略、任务每步更新不同，它**并非每步更新**，其演化由两式刻画。其一，系统持续收集失败案例集 $\mathcal{B}_{t'}$ （下标 t' 表示其按独立的低频周期累积， $t' \leq t$ ）；当且仅当满足触发条件（每隔若干训练步或累积到一定数量失败案例）时，由大模型对 $\mathcal{B}_{t'}$ 归因，产出对评估器/基建的增量更新 $\Delta_{t'}$ ：

$$\mathcal{B}_{t'} \xrightarrow{\text{Attribution}} \Delta_{t'} \quad (3.6)$$

其二，该增量作用于当前状态，得到下一步生效的评估器与基建状态：

$$\Phi_{t+1} = \begin{cases} \Phi_t \oplus \Delta_{t'}, & \text{触发更新时} \\ \Phi_t, & \text{否则} \end{cases} \quad (3.7)$$

式 3.6 刻画“失败案例如何转化为改进项”——由大模型综合任务意图、轨迹与环境证据归因，区分根因在模型侧还是基建侧，产出相应的提示词修订或基建扩展 $\Delta_{t'}$ ；式 3.7 刻画“改进项如何作用于系统”——以 $\oplus$ 表示将增量并入当前配置（提示词增量修订、基建能力补齐），且多数训练步不触发更新（ $\Phi_{t+1} = \Phi_t$ ）。

两个下标解耦： t 为**训练步**计数、每步递增， t' 为**失败案例累积周期**计数、随触发缓慢递增。

由此，本文的自进化包含两条更新频率不同的支路：一是每步同步演化的**主循环**（任务 Q 、策略 θ 、沙箱状态 s ），二是低频触发的**评估器与基建演化**（ Φ ）。二者共同将自进化的对象从传统强化学习仅有的“策略”扩展到“任务、策略、评估器、基建”四维，这是本文与传统强化学习的本质区别。四类状态在训练轮次间的传递即构成系统的数据流：其中策略、沙箱、任务三类每步同步更新，其相邻训练步之间的传递关系如图 3.1 所示；评估器与基建则与训练步解耦、沿 $\Phi_0 \rightarrow \Phi_1 \rightarrow \Phi_2 \rightarrow \dots$ 低频演进，其与主循环的时间关系如图 3.2 所示。




图 3.1 每步同步更新的三类状态在训练轮次间的传递：策略、沙箱、任务

3.4 核心问题

围绕上述过程与形式化，本文需要解决四个核心问题：

核心问题一：如何自主产生交互轨迹与下一轮任务？这是自进化数据供给的核心。与依赖人工标注数据、人工构建运行环境的传统范式不同，自进化系统需在极少人工介入下自主产生训练数据：一方面借助系统内多智能体的协作（执行者探索、观察者取证、提问者追问）与历史经验持续生成新的交互轨迹与后续任务，另一方面以上一轮沙箱状态为基础、通过状态的跨步继承与演化产生新的运行环境，从而支撑训练闭环的持续运转。

核心问题二：如何使奖励锚定环境真实状态？人工干预的减少会使训练过程更难约束，也为奖励作弊提供了更大空间——策略可能仅在自述轨迹中谎报完成而裁判无从核实。因此在此场景下抗奖励作弊尤为关键，需要观察者产出确定性的环境状态差分，使裁判据此打分，而非依赖智能体的自我叙述。

核心问题三：如何自监控自进化过程？自进化系统长时间无人值守地自主运转，一旦出现策略坍缩或训练崩溃而未被及时发现，后续所有训练步都将在无效信号上空转，白白消耗大量计算资源，甚至可能得出错误结果。因此需要实时监控关键指标，并在坍缩或崩溃发生时自动终止训练。

核心问题四：如何让评估器与基建随训练自我完善？训练中会持续暴露系统性失败，需要一种机制自动收集失败案例，并由大模型判别其根因落在**模型侧**（策略的规划、工具使用或方案选择失误）还是**基建侧**（沙箱、工具、执行环境的缺陷），进而分别对评估器提示词进行增量修订、或将缺失的基建能力补齐为可复用技能，避免同类失败反复积累。

3.5 系统研究边界

一个完整的自进化系统可在算法、模型规模、沙箱形态、评估方式等多个维度上无限扩展，若不加界定，极易使研究范围过度膨胀、实现日趋繁杂，反而模糊本文真正要论证的核心命题。为此，本节明确划定本文的**研究边界**：在若干维度上采用固定或简化的设定，将研究精力集中于“数据与奖励的自主供给及自进化闭环的

自我维持”这一核心问题，而不在与该问题正交的方向上求全。据此，本文作如下界定：

- **基座模型固定。**基座模型固定为 Qwen3.5-9B^[45]。Qwen3.5-9B 模型规模适中，具备一定的推理能力、工具调用能力与代码执行能力，且在中文与英文的文本任务上均有较好表现，但仍有较大的提升潜力，适用于算法验证和实验。
- **策略优化算法固定。**实验的策略优化采用标准 GRPO 算法。本文不改进底层 RL 算法、亦不追求算法最优，算法仅作为验证自进化闭环可行性的既定组件。
- **研究范围为纯文本任务。**本文将研究范围限定为**纯文本模态**的智能体任务，即任务描述、工具调用、环境反馈与交付物均以文本形式表示，运行于支持文件系统操作与命令执行的代码沙箱（本地或云端）；不涉及图像、音频、GUI 操作、具身控制等多模态交互形态。这一限定是为了快速推进实验，证明系统可行性。可以通过引入相应的状态表示与取证手段来扩展多模态相关能力，这属于正交的工程外延，不改变本文机制的本质。
- **裁判权重冻结。**本文没有专门为强化学习过程训练一个专门的奖励模型，奖励模型为权重冻结的大模型接口，以服务形式提供，训练过程中其**模型权重**保持不变，但其打分所用的**提示词**属于评估器状态 Φ_t ，可由失败案例驱动演化。即本文只演化评估器的提示词而不训练裁判本身，避免引入裁判与策略共同训练带来的耦合与不稳定。
- **训练规模服务于验证目的。**训练步数不设固定值，由稳定性终止判据决定；但为控制实验时间和成本，同时为方便与传统强化学习训练效果对比，本文中验证自进化可闭环执行的强化学习实验步数限制上限为 50 步。规模以验证系统端到端可运行、闭环可自我维持为目标，而非追求模型能力在具体任务上的绝对提升。

上述边界并非系统机制上的约束或能力上的局限，而是**有意的范围控制**：通过在正交维度上固定设定、抑制系统复杂度的无谓膨胀，使本文得以聚焦并清晰地论

证自进化机制本身的有效性；这些被固定的维度在系统跑通后均可作为独立的工程或研究方向进一步展开。

3.6 本章小结

本章建立了自进化强化学习的问题模型。首先将传统固定任务集的训练范式扩展为任务动态生成的闭环过程，以系统状态转移算子 $\mathcal{T}$ 给出整体形式化，再按阶段展开为 $Q_t \rightarrow \pi_{\theta_t} \rightarrow \tau_t \rightarrow R_t \rightarrow \theta_{t+1} \rightarrow Q_{t+1}$ 的主循环，以及由失败案例集 $\mathcal{B}_{t'}$ 驱动的 $\Phi_t \rightarrow \Phi_{t+1}$ 评估器与基建演化支路，明确了策略、沙箱、任务、评估器与基建四类状态的传递。最后界定了四个核心问题与研究边界。后续章节围绕这些问题与形式化结论展开方法设计与系统实现。

第 4 章 自进化强化学习方法设计

根据系统的组织思路和贡献，本章按“总一分”结构展开方法设计：先给出统领全局的方法总体框架，再依次阐述与绪论章所述的六项主要贡献一一对应的六个核心机制，以及与这六项机制相对应的方法设计。本章聚焦系统设计的原理和运作机制，各机制相应的工程实现步骤见第五章。

六个核心机制依次为：跨步自进化任务生成（贡献一）、多智能体协作机制（贡献二）、超采样-淘汰-选组（贡献三）、差分驱动奖励（贡献四）、失败案例驱动的评估器与基建自演化（贡献五）、自进化稳定性控制（贡献六）。

4.1 方法总体框架

传统非自进化的智能体强化学习遵循“固定任务集—固定基建完成任务—采样—固定评估函数给予奖励—更新策略”的开环流程：任务由外部一次性给定、评估函数、推理与采样基建在推理与训练过程中全程固定，模型只是被动地在既有数据上优化策略。本文将扩展为“任务生成—环境交互—状态观测—奖励评估—策略更新—任务再生成”的闭环过程：任务不再外部给定，而是由系统基于上一轮执行经验持续再生成；奖励不再依赖固定评估函数，而是锚定于观察者对环境真实状态的观测；评估器与基建也不再全程固定，而是由失败案例驱动、随训练周期性地自我修订与扩展；每一轮的策略与产物又成为下一轮任务生成的起点，从而让任务、经验、策略与评估器/基建在闭环中协同演化。方法总体框架如图 4.1 所示。

一个训练步内， S 个任务经执行者在沙箱中与环境交互并 **rollout** 产生 $S \times n$ 条轨迹（ n 为 **GRPO** 组大小），观察者对每条轨迹产出确定性状态差分，裁判据此打分；随后淘汰低质组、选梯度最优组做 **GRPO** 更新；训练步结束后，系统对




图 4.1 自进化强化学习方法总体框架

存活组再生成下一轮任务，形成自进化闭环。第一步任务数 $S = 2N$ (N 为训练组数，任务来自初始种子)，后续步 $S = R$ (上一轮存活组数，任务由系统再生成)。

上述闭环之上，本文的自进化包含**两条更新频率不同的演化支路**，与第三章的形式化定义一致：其一是**每步更新的主循环**——任务、策略与沙箱状态在每个训练步同步演化（策略经 GRPO 更新、任务由提问者跨步再生成、沙箱状态跨步继承）；其二是**低频触发的支路**——评估器与基建状态 Φ_t 并非每步更新，而是由失败案例集 $\mathcal{B}_t$ 驱动、周期性触发地演化，使评估口径与执行环境随训练持续自我完善。两条支路共同将自进化的对象从传统强化学习仅有的“策略”扩展到“任务、策略、评估器、基建”四维。图 4.1 只刻画每步更新的主循环，评估器与基建的演化支路已在第三章图 3.2 单独给出，其机制细节见本章第 4.6 节。

以下六节分别阐述框架中的各个机制。

4.2 跨步自进化任务生成机制

跨步自进化任务生成是本文自进化闭环的核心机制，使系统除初始种子外能自主产生所有后续训练任务。其要解决的根本问题是：在不依赖外部数据补给的前提下，如何让训练任务的来源可持续、且难度与策略当前能力相匹配。传统做法从固定题库采样，题目与模型能力脱节——过易则同组轨迹大多成功、过难则大多失败，两种情形下组内奖励都趋于一致、缺乏分化，GRPO 据以估计的优势随之趋零，产生不了有效梯度信号；而单纯让模型凭空生成新题，又会因缺乏环境依据而产出空泛、不可执行或与已有产物无关的任务。本机制的核心思想是：**以上一轮执行后的真实系统状态为依据、经智能体间的博弈产生下一轮任务**——观察者对沙箱执行前后的状态变化进行客观观测，提问者以该状态观测为输入、扮演具有人设的模拟用户向执行者追加需求，二者的交互使新任务锚定在已产出的环境状态之上，从而使任务序列形成一条有环境依据、难度递进的演化链。跨步自进化闭环如图 4.2 所示。

每个训练步完成后，系统执行以下跨步流程：

(1) 取存活组最优轨迹。从淘汰后的存活组中，每组取奖励最高的轨迹及其沙箱状态，作为该任务线的“最佳延续点”。之所以取最优轨迹而非任意轨迹，是为




图 4.2 跨步自进化闭环

了让下一轮站在本轮质量最高的产物上继续，避免在低质或失败的中间态上追加需求；之所以每个存活组各取一条，是为了保持任务的多样性——不同组对应不同的任务线，各自独立延续，防止任务空间过早收敛到单一方向。

(2) 执行概括（随机启用）。观察者用大模型概括上轮最优轨迹的执行情况——做了什么、产出了什么、还差什么。这里以概括替代原始轨迹回填，根本原因在于**避免离策略（off-policy）与分布偏移问题**：上一轮轨迹由旧策略 π_{θ_t} 生成，若将其原文直接拼入下一轮 $\pi_{\theta_{t+1}}$ 的输入上下文，等于让新策略在旧策略的具体生成内容上续写，训练样本的前缀分布与当前策略脱节，引入离策略偏差；同时模型会倾向模仿旧轨迹的措辞与操作路径，造成风格与策略层面的自我强化，逐轮累积分布偏移。经观察者重新组织的概括只保留“意图—产物—缺口”这一任务层面的客观信息、剥离了旧策略的具体生成痕迹，既压缩了上下文，又使下一轮任务的表述独立于生成它的策略，从而缓解上述偏差；概括亦为提问者提供了恰当粒度的追问依据。

本文进一步将执行概括设为**随机启用**，由此在同一套跨步流程下产生两种互

补的任务模式：**(i) 延续模式（启用概括）**：提问者获得上一轮的意图—产物—缺口，追问自然承接已有工作（如“在上一轮的报表上补充同比分析”），配合沙箱状态继承，形成在真实产物上层层递进的长程任务链；**(ii) 新任务模式（不启用概括）**：提问者仅面对继承下来的沙箱环境、不获知上一轮的执行意图，于是倾向于就当前环境状态提出一个全新、不依赖历史意图的任务（如“基于工作区现有的数据文件做一次异常检测”）。随机在两种模式间切换有三重收益：其一，提升生成任务的多样性，避免任务链单调地朝单一方向延伸；其二，两种模式对策略提出不同要求——延续模式训练“在既有成果上持续深化”的长程能力，新任务模式训练“面对陌生环境状态快速切入”的冷启动能力，二者兼顾使训练覆盖更全面；其三，新任务模式贴合长尾、离散的任务分布——真实任务并非都是前一任务的延续，随机断开概括正是对这类非连续任务的模拟，使系统同时兼容连续追问与长尾独立任务两类训练数据。

需要说明的是，执行概括之所以采用随机启用而非对每一轮都附加，是出于对任务分布多样性的保护。若每轮都强制提供执行概括，提问者将始终被引导去承接上一轮的意图与缺口、持续提出“后续追问”，任务序列因而被约束在一条单向延伸的延续链上：其起点、领域与关注偏好均由最初的种子经逐轮传递而高度相关，生成任务的条件分布随之收窄。这一收窄会沿两个层面向训练传导：在任务层面，任务空间的有效熵逐轮递减，长程演化下退化为围绕少数主题的同质变体；在策略层面，同质任务使各 GRPO 组内轨迹趋同、组内奖励标准差下降，可用的梯度对比信号减弱——这正是第三章所刻画的向坍缩不动点收敛的诱因之一。换言之，全程附加概括会以“强制承接”的方式主动降低系统熵，加剧模式坍缩的风险。将概括随机断开，等价于以一定概率向任务分布注入不依赖历史意图的独立样本，为演化链持续补充新的方向与熵，从而在保留长程深化能力的同时抑制分布收窄，这与第六节稳定性控制维持策略多样性的目标一致。

(3) 沙箱状态继承。将上轮最优轨迹的沙箱文件系统状态传递到本轮新沙箱，使智能体在上轮产出的文件基础上继续工作。这是**环境状态层面的真继承**，而非仅**文本描述**——两者的区别是本机制区别于文本层面自进化工作的关键：若仅把“上轮产出了 report.csv”写进任务描述，模型下一轮面对的是一个空沙箱，必须凭空重建或假想该文件的内容，任务与环境随即脱节；而真状态继承让 report.csv

及其真实内容实际存在于新沙箱中，模型可以直接读取、追加、修正，任务因而能在真实产物上有意义地递进（如“在你上一轮生成的报表基础上补充同比分析”）。

（4）任务再生成。提问者基于当前沙箱状态、并视随机策略决定是否结合执行概括，生成符合人设的新任务（启用概括时承接上一轮工作，否则就当前环境提出新任务）。任务由人设驱动而非随机扰动，使追问带有一致的关注偏好（如财务人设盯数字、运维人设盯稳定性），任务序列因而更贴近真实用户的连续交互。本轮任务数 S 等于上一轮存活组数 R ，超采样量随淘汰动态收缩——这一收缩特性亦是自进化能否自我维持的观测量： R 长期不低于训练组数 N ，意味着系统在无外部补给下仍能持续产出足量可训练任务。

上述跨步流程的伪代码如算法 4.1 所示。

算法 4.1 跨步自进化任务生成

输入： 存活组集合 $\mathcal{R}$ ，各组轨迹及沙箱状态，人设集合 $\mathcal{P}$ ，概括启用概率 p

输出： 下一轮任务集 Q_{t+1} 及其继承沙箱

```

1:  $Q_{t+1} \leftarrow \emptyset$ 
2: for each 存活组  $g \in \mathcal{R}$  do
3:    $\tau^* \leftarrow \arg \max_{\tau \in g} r(\tau)$                                 ▷ 取组内奖励最高的轨迹
4:    $s^* \leftarrow \text{Snapshot}(\tau^*)$                                 ▷ 最优轨迹的沙箱终态
5:   if  $\text{Rand}() < p$  then                                ▷ 随机决定是否启用概括
6:      $u \leftarrow \text{Observer.Summarize}(\tau^*)$                                 ▷ 意图—产物—缺口
7:   else
8:      $u \leftarrow \emptyset$                                 ▷ 新任务模式：不提供历史意图
9:   end if
10:   $s_{\text{new}} \leftarrow \text{Inherit}(s^*)$                                 ▷ tar 快照 → 新沙箱，真状态继承
11:   $q \leftarrow \text{Questioner}(\text{Persona}(g), s_{\text{new}}, u)$                                 ▷ 人设驱动生成任务
12:   $Q_{t+1} \leftarrow Q_{t+1} \cup \{(q, s_{\text{new}})\}$ 
13: end for
14: return  $Q_{t+1}$ 
    
```

失败模式与缓解。本机制在实践中可能出现三类失败，均已在设计中给出缓

解：（1）**任务漂移**——提问者脱离沙箱状态凭空生成、产出与已有产物无关的任务；缓解措施是强制以观察者的客观状态报告为输入、并要求追问引用报告中真实存在的产物。（2）**难度失配**——再生成的任务过易（无梯度）或过难（全盘失败）；缓解措施是任务生长在上一轮真实产物之上、以人设的连续关注点自然递进，使难度与策略当前能力相匹配，并由后续超采样-淘汰环节滤除退化组。（3）**任务空间坍塌**——若每组只延续单一方向，任务多样性会过早收敛；缓解措施是每个存活组各自独立延续、并随机在延续模式与新任务模式间切换，维持任务空间的宽度。

4.3 多智能体协作机制

多智能体协作机制关心的是自进化数据生产中的**角色分工**问题：贡献一解决的是任务从何而来（跨步再生成），本机制则解决由谁、以何种分工来完成一次采样——把一次采样从孤立的“查询—回答”组织成一段由多个角色协同完成的自主交互经验。其设计出发点是：自进化训练所需的数据不是静态的问答对，而是**带环境反馈、可追问、可取证**的交互轨迹；而单个模型自问自答无法同时胜任“求解、客观取证、模拟用户追问”这三种性质迥异的角色——求解与追问是开放性生成，天然适合大模型，取证却要求绝对客观、不可被求解者操纵。若由同一模型兼任，取证便沦为求解者的自我背书，奖励随即失去可信基准。本机制据此按“**能力与确定性分离**”的原则将三种职责拆给三个协同智能体，其协作关系如图 4.3 所示。

从数据来源的视角看，本文的训练数据并非取自任何外部语料，而是由**系统内各单元之间的相互博弈**动态产生：提问者作为模拟用户不断向执行者提出并追加需求，执行者在沙箱环境中通过工具调用与之博弈、试图交付满足要求的产物，观察者与冻结裁判则以环境的真实状态差分为准绳对执行结果作客观裁决——三个智能体、沙箱环境与裁判构成一个持续互动的多方系统，任务、轨迹与奖励都在这一互动过程中涌现。这种“智能体—智能体、智能体—环境”的双重博弈，一方面使数据的产生不依赖人工标注与外部采集，另一方面通过提问者持续追问、裁判据实评分，迫使执行者策略在博弈中不断改进，形成数据生成与能力提升相互驱动的正向循环。这与自我博弈（self-play）类方法^[10]“在对抗/协作互动中自动生成训练信号”的思想一脉相承，区别在于本文的博弈发生在真实沙箱环境中、并以环境

状态而非纯文本作为裁决依据。




图 4.3 多智能体协作机制

执行者 (actor): 被训练的策略 π_θ ，在代码沙箱中以 ReAct 方式多步调用工具求解任务，产生交互轨迹。它是唯一被 GRPO 更新的角色，其余两个智能体均为冻结的辅助角色，只服务于数据生成与取证，不参与梯度更新——这一界定保证了训练目标始终是执行者策略本身。

观察者 (observer): 在轨迹执行前后对沙箱状态各拍一次快照，作差得到确定性状态差分（文件系统变更及内容、系统状态变更），产出客观状态报告。观察者的关键约束是只依据环境证据、不采信执行者自述：它看到的是沙箱的真实前后状态，而非执行者“声称做了什么”，因而其报告可作为奖励评估与追问的可信基准。

提问者 (questioner): 扮演具有人设的模拟用户，在跨步自进化时基于观察者的状态报告与执行概括生成下一轮任务。它替代了真实用户在数据回流中的角色，使“追问”这一环节也自主化。

实现与思路。三个角色的分工遵循“能力与确定性分离”的原则：产生数据与追问任务是开放性生成，交由大模型驱动的执行者与提问者完成；而奖励取证要求客观、不可被策略操纵，因此其证据来源是沙箱执行前后快照的确定性差分，而非任何模型的自由生成——这是差分驱动奖励可信的物理基础（观察者在此确定性差分之上组织报告）。工程上，三者通过同一个沙箱会话串接以保证取证的一致性：执行者在沙箱内运行 **ReAct** 循环，观察者在同一沙箱的执行前后各注入一次只读探针（文件系统 + 系统状态），提问者则在跨步时以观察者的状态报告与执行概括为输入。三者串接使一次采样成为“提问—执行—取证”的完整闭环：提问者定义任务、执行者在真实环境中求解、观察者客观记录结果，产出的经验既可用于当轮奖励评估，又可作为下一轮跨步自进化的继承素材，全程无需人工标注。

一次多智能体协作采样的伪代码如算法 4.2 所示。

算法 4.2 多智能体协作的单次采样

输入： 任务 q 与其继承沙箱 s ，被训练策略 π_θ ，最大轮数 T

输出： 交互轨迹 τ 、状态差分 d 、观测报告 rep

```

1: before  $\leftarrow$  Observer.Probe( $s$ )    ▷ 执行前只读快照（文件系统 + 系统状态）
2:  $\tau \leftarrow \emptyset$ 
3: for  $k = 1$  to  $T$  do                                ▷ 执行者在沙箱内 ReAct
4:   (thought, action)  $\leftarrow \pi_\theta(q, \tau)$ 
5:    $o \leftarrow$  Sandbox.Exec(action)                ▷ 工具调用返回观察
6:    $\tau \leftarrow \tau \parallel (\text{thought}, \text{action}, o)$ 
7:   if IsDone( $\tau$ ) then break
8:   end if
9: end for
10: after  $\leftarrow$  Observer.Probe( $s$ )                ▷ 执行后只读快照
11:  $d \leftarrow$  Diff(before, after)                ▷ 确定性状态差分（GROUND TRUTH）
12: rep  $\leftarrow$  Observer.Report( $d$ )                ▷ 客观报告；不采信执行者自述
13: return ( $\tau, d, \text{rep}$ )
    
```

失败模式与缓解。（1）**取证被污染**——若观察者采信执行者自述而非环境证

据，取证即失去客观性；缓解措施是观察者仅注入只读探针、只读取沙箱真实前后状态，结构上不接触执行者的声明。（2）**提问者“AI腔”**——模拟用户若语气生硬、缺乏人设一致性，会偏离真实用户分布；缓解措施是以固定人设与语气指引约束提问者、并要求其基于报告的具体产物追问。（3）**沙箱会话不一致**——若三个智能体不共享同一沙箱会话，前后快照将无法对齐、差分失真；缓解措施是三者串接在同一沙箱会话上，保证 **before/after** 探针作用于同一环境实例。

4.4 超采样-淘汰-选组机制

超采样-淘汰-选组机制将推理与训练解耦，以“多推理、少训练”提升每步训练信号质量，如图 4.4 所示。




图 4.4 超采样-淘汰-选组机制

超采样 (Sample)：推理阶段用 S 个任务，每个复制 n 份，rollout 产生 $S \times n$ 条轨迹。第一步 $S = 2N$ ，后续步 $S = R$ 。

淘汰 (Eliminate)：丢弃同时满足以下两个条件的组，至少保留 80%：（1）组内最大 reward 处于所有组的后 20%；（2）组内最大 reward 低于阈值 0.5。残缺组（因 rollout 失败不足 n 条）直接丢弃。淘汰后剩 R 组。只有最大 reward

低而组内 reward 分化大（高 $|\hat{A}|$ ）的组不会被淘汰，因为这类组仍具有可学习的梯度对比信号。

选组 (Select): 按组内优势绝对值均值降序，选梯度最强的 N 组 ($N \times n$ 条) 做 GRPO 训练。

推理超采样 $S \times n$ 、训练只用 $N \times n$ ——超采样量提供了淘汰与选组的样本池，但不进梯度更新。以“多推理少训练”提升每步训练信号质量。

超采样-淘汰-选组的伪代码如算法 4.3 所示。

算法 4.3 超采样-淘汰-选组

输入: S 组各 n 条轨迹的奖励 $\{r_{ij}\}$ ，训练组数 N ，淘汰阈值 $\theta_r=0.5$ ，保留下限 80%

输出: 进入 GRPO 更新的 N 组轨迹

- 1: 计算各组最大奖励 $M_i \leftarrow \max_j r_{ij}$ ，并求其在所有组上的后 20% 分位 q_{20}
 - 2: $\mathcal{E} \leftarrow \{i : M_i \leq q_{20} \text{ and } M_i < \theta_r\}$ ▷ 同时满足两条件才淘汰
 - 3: 丢弃残缺组 (rollout 不足 n 条) 并入 $\mathcal{E}$
 - 4: 限制 $|\mathcal{E}|$ 使存活组数 $\geq \lceil 0.8S \rceil$ ▷ 至少保留 80%
 - 5: $\mathcal{R} \leftarrow \{1, \dots, S\} \setminus \mathcal{E}$; $R \leftarrow |\mathcal{R}|$ ▷ 存活 R 组
 - 6: **for each** 组 $i \in \mathcal{R}$ **do**
 - 7: $\hat{A}_{ij} \leftarrow (r_{ij} - \mu_i) / (\sigma_i + \epsilon)$; $g_i \leftarrow \frac{1}{n} \sum_j |\hat{A}_{ij}|$ ▷ 组级信号强度
 - 8: **end for**
 - 9: $\mathcal{S} \leftarrow$ 按 g_i 降序取前 $\min(N, R)$ 组 ▷ 选梯度最强组
 - 10: **return** $\mathcal{S}$ 对应的 $|\mathcal{S}| \times n$ 条轨迹
-

失败模式与缓解。（1）**误淘高价值难题**——最大奖励低但组内分化大的组仍含可学习的梯度对比信号，若仅按奖励高低淘汰会误删；缓解措施是淘汰需同时满足“最大奖励处于后 20%”与“低于阈值 0.5”两个条件，高分化组因而得以保留。（2）**存活组不足**——前期模型弱、大量组低分，若无下限会淘汰过猛导致可训练组骤减；缓解措施是设“至少保留 80%”的下限，并允许变长分组进入训练。（3）**信号池枯竭**——若存活组数长期低于训练组数 N ，选组无从满额；这被纳入稳定性监控（存活组数判据），触发即终止。

4.4.1 为何训练只需 N 组：理论分析

一个自然的问题是：既然推理阶段已经产生了 $S \times n$ 条轨迹，为什么不全用于训练，而只选 N 组？本节从梯度信号质量的角度给出理论论证：训练所需的不是轨迹数量，而是单位计算所能获得的有效梯度信号；在固定的训练预算下，选择优势信号最强的子集能最大化每步的策略改进。

(1) GRPO 的梯度由组内优势驱动，零优势组不产生有效更新。

GRPO 对同一查询的一组轨迹做组内奖励归一化估计优势。设第 i 组（查询 q_i ，组大小 n ）内轨迹 j 的奖励为 r_{ij} ，组内优势为

$$\hat{A}_{ij} = \frac{r_{ij} - \mu_i}{\sigma_i + \epsilon}, \quad \mu_i = \frac{1}{n} \sum_{j=1}^n r_{ij}, \quad \sigma_i^2 = \frac{1}{n} \sum_{j=1}^n (r_{ij} - \mu_i)^2 \quad (4.1)$$

GRPO 的策略梯度为

$$\nabla J(\theta) = \mathbb{E}_{i,j} \left[\hat{A}_{ij} \nabla_{\theta} \log \pi_{\theta}(y_{ij} | q_i) \right] \quad (4.2)$$

其中 y_{ij} 为第 i 组第 j 条轨迹。注意式 4.2 的结构：梯度更新完全由 $\hat{A}_{ij}$ 加权的对数概率梯度构成。考察两类退化组：

- **全对组**（所有轨迹都完成， r_{ij} 几乎相同）： $\sigma_i \rightarrow 0$ ，则 $\hat{A}_{ij} \rightarrow 0$ ，该组对梯度的贡献趋于零——把这类组放进训练批次只是消耗计算，不产生有效更新。
- **全错组**（所有轨迹都失败， r_{ij} 相同且低）：同理 $\hat{A}_{ij} \rightarrow 0$ 。全错组不仅无梯度贡献，还会拉低批内优势的整体尺度。

因此 GRPO 训练真正依赖的是**组内奖励存在分化**的组：一部分轨迹成功、一部分失败， σ_i 大、 $|\hat{A}_{ij}|$ 大，梯度信号强。这也与近期理论工作^[23]的结论一致：GRPO 方差缩减的效果主要由每步有效 rollout 总数驱动——关键在“有效”，即具有优势对比的样本，而非轨迹的原始数量。

(2) 固定训练预算下的最优子集选择。

设淘汰后存活 R 组，每组定义组级信号强度指标

$$g_i = \frac{1}{n} \sum_{j=1}^n |\hat{A}_{ij}| \quad (4.3)$$

g_i 度量该组平均能贡献的梯度幅度（PPO/GRPO 损失对优势的导数幅度与 $|\hat{A}|$ 成正比）。训练预算限制每步最多训练 N 组（受 `ppo_mini_batch` 与显存约束）。于是选组问题为：

$$\mathcal{S}^* = \arg \max_{\mathcal{S} \subseteq \{1, \dots, R\}, |\mathcal{S}|=N} \sum_{i \in \mathcal{S}} g_i \quad (4.4)$$

这是一个基数约束下的线性最大化问题，其最优解显然是按 g_i 降序取前 N 组——即本文的选组规则。直观上：每步训练的计算预算固定时，把预算花在“一部分能学会、一部分学不会”的任务上收益最大；全对与全错的任务处于策略当前能力的两侧，都不提供可学习的对比信号。

（3）被选组与被弃组的信号量对比。

超采样的意义不在于“多训练”，而在于“扩大候选池后再精选”。将 R 组按 g_i 降序排列， $g_{(1)} \geq g_{(2)} \geq \dots \geq g_{(R)}$ 。选前 N 组获得的信号量为 $\sum_{k=1}^N g_{(k)}$ 。若改为随机选 N 组，期望信号量为 $\frac{N}{R} \sum_{k=1}^R g_{(k)}$ 。两者的比值为

$$\rho = \frac{\sum_{k=1}^N g_{(k)}}{\frac{N}{R} \sum_{k=1}^R g_{(k)}} \geq 1 \quad (4.5)$$

ρ 恒不小于 1（前 N 大的均值必不小于总体均值），且组间信号强度分化越大（实践中奖励分布长尾、多数组趋同于全对/全错时）， ρ 越大。也就是说：**在同样的 N 组训练预算下，从 $R > N$ 的候选池中优选出的组，单位计算获得的梯度信号严格优于随机选取 N 组、也优于将全部 R 组均摊训练**。而“将 $R \times n$ 全部用于训练”的方案虽纳入了信号量 g_i 较小的组，却需付出 R/N 倍的训练计算与更长的单步时长——在每步预算固定、训练总步数受限的设定下，全量训练等价于将每步预算稀释到低信号组上。

综上， N 的取值由训练预算决定（本文 4 卡 $N=16$ 、16 卡 $N=64$ ），而“只训 N 组”的合理性由信号密度论证保证：超采样扩大候选池、淘汰剔除退化组、选组把固定预算集中于优势对比最强的组，使每步策略改进的期望最大化。

4.5 差分驱动奖励机制

差分驱动奖励机制使奖励锚定环境真实状态而非智能体自述，是本文抵御奖励作弊的核心设计，如图 4.5 所示。其针对的问题是：在开放的智能体任务上没有标准答案可比对，若让裁判直接阅读执行者自述的轨迹文本打分，策略会迅速习得“在轨迹里把话说漂亮”这一捷径——声称完成、编造产出、夸大结果——而裁判无从核实，奖励随即与真实完成度脱钩。




图 4.5 差分驱动奖励

本机制的核心是把打分的证据基准从“智能体说了什么”换成“环境里真实发生了什么”。外部冻结的大模型裁判依据观察者的确定性状态差分（文件系统变更及其内容、系统状态变更）打分，执行者的自我声明仅作交叉核对而非评分依据——当执行者“声称写入 12345”而差分显示实际写入 99999 时，二者矛盾被直接暴露，裁判据真实差分给分。由于状态差分由沙箱前后快照作差确定性地得到、不可被策略的措辞操纵，作弊的收益被从根本上切断：说得再漂亮，若环境中没有对应产物，差分即为空。

评分采用**多维度打分后乘性聚合**：裁判从任务完成度、正确性、轨迹质量等维度分别评分，各维度得分相乘得到最终奖励；乘性聚合意味着任一关键维度为零则总分为零，避免了加性聚合下“靠某几维刷高分掩盖关键维度失败”的漏洞（例如轨迹看似规整但产物完全错误，不应得到中等分）。其中**安全维度设为二元门控**：一旦触发不安全行为直接将奖励置零，而非按比例扣分，以确保安全约束不可被其他维度的高分抵消。

差分驱动奖励的计算流程如算法 4.4 所示。

算法 4.4 差分驱动奖励计算

输入： 状态差分 d ，执行者自述轨迹 a ，任务 q ，冻结裁判 Judge

输出： 奖励 $R \in [0, 1]$

```

1:  $\{c_k\} \leftarrow \text{Judge}(d, q)$     ▷ 多维度打分：完成度/正确性/轨迹质量等，以  $d$  为证据
2:  $b_{\text{safe}} \leftarrow \text{Judge.Safety}(d, a)$     ▷ 安全维度：二元/分级门
3:  $\text{CrossCheck}(a, d)$     ▷ 自述与差分交叉核对，矛盾以  $d$  为准
4: if  $b_{\text{safe}} = 0$  then    ▷ 触发不安全行为
5:     return 0    ▷ 安全门直接清零
6: end if
7:  $R \leftarrow b_{\text{safe}} \cdot \prod_k c_k$     ▷ 多维乘性聚合：任一关键维为零则总分为零
8: return  $R$ 
    
```

失败模式与缓解。（1）**话术作弊**——策略在轨迹里谎报完成；缓解措施是把打分证据基准从自述换为确定性状态差分，说得再漂亮而环境无对应产物，差分也不会体现，裁判据真实差分给分。（2）**维度刷分**——加性聚合下靠某几维刷高分掩盖关键维失败；缓解措施是采用乘性聚合，任一关键维为零则总分为零。（3）**安全被高分抵消**——危险操作被其他维度高分冲抵；缓解措施是安全维设为二元/分级门，触发即整体清零，不参与加权。（4）**裁判自身盲区**——rubric 存在系统性打分偏差；缓解措施是把裁判提示词纳入评估器状态 Φ_t ，由失败案例自演化机制持续修订（下节）。

4.6 失败案例驱动的评估器与基建自演化机制

前述机制演化的是**任务**（跨步自进化）与**策略**（GRPO 更新）。然而按第三章的形式化定义，一个完整的自进化智能体除策略 θ_t 、任务 Q_t 外，还应演化其**评估器与基建状态** Φ_t ——即奖励与提问的提示词、以及沙箱、工具、执行环境等基建。若评估器与基建固定不变，训练中暴露的系统性缺陷将无法自我修复：裁判的打分口径若有盲区，模型会持续在该盲区上作弊而奖励无从察觉；基建若缺少某类工具或超时过短，相关任务将长期无法完成而积累无效轨迹。本机制以**失败案例（badcase）**为驱动，令系统在训练过程中周期性地反思并演化评估器与基建，补齐这一维度。失败案例驱动自演化流程如图 4.6 所示。




图 4.6 失败案例驱动的评估器与基建自演化流程

（1）失败案例收集与触发。系统在训练过程中持续收集失败案例，其判据除执行层面的信号（奖励极低、执行报错、零交付且状态差分为空）外，还包括一类评估器侧的偏差信号：当裁判给出的正确性或一致性维度得分与奖励总分出现明显

偏差——无论是维度分高而总分反常地低，还是维度分低而总分反常地高——都说明维度评分与聚合结果之间存在不一致，提示评估器的评分口径可能存在缺陷，该轨迹被留作失败案例供归因审查。这类偏差信号是**评估器缺陷被发现的主要来源**：单条轨迹的维度得分与总分之间的矛盾，正是评分函数在特定情形下失准的直接证据。每个失败案例连同其任务描述、完整轨迹、观察者状态差分、工具报错等取证信息一并留存。触发条件为二者之一：每累计 10 个训练步、或攒够 20 个失败案例，即自动触发一次演化，兼顾及时性与批量反思的稳定性。

(2) 大模型归因，而非规则判断。每个失败案例的根因需区分为**模型问题**（策略本身的规划、工具使用或方案选择失误）与**基建问题**（沙箱、工具、代码执行环境、harness 基建的缺陷）。这一归因由**大模型综合判断，而非自动程序按规则判定**——因为二者的表象常常重叠，规则判断不可靠。例如一次内存溢出（OOM）失败：既可能是基建内存配额不足（基建问题），也可能是模型选用了暴力全量搜索的低效方案导致资源耗尽（模型问题）。仅凭错误码无法区分，必须由大模型结合任务意图、轨迹中的方案选择、以及环境证据综合研判，才能给出可靠归因。

(3) 分流处理与演化。依归因结果分两路演化：

- **模型问题 → 演化提示词。**大模型诊断当前失效的模式（如裁判 rubric 存在盲区、提问者生成的任务超出策略能力、执行者的系统提示缺少某类约束），产出提示词的**增量修订**，热更新裁判、提问者或执行者的相应提示词，使下一轮评估与生成更贴合真实情况。采用增量追加而非整体重写，以保证可回滚、不漂移。
- **基建问题 → 动态扩展基建。**大模型识别缺失的基建能力（如缺少某类工具、沙箱缺少依赖库、工具超时过短、harness 对某类返回处理不当），产出对应的基建扩展项（注册新工具、补装依赖、调整超时或并发、修正 harness 处理逻辑），动态扩展系统基建，使原本无法完成的任务在后续轮次中可被正常执行。

经此机制，评估器与基建不再是训练全程固定的静态组件，而是随失败案例暴露的问题持续自我修正——这使系统的自进化从“任务与策略”二维扩展到“任务、策略、评估器、基建”四维，更接近完整的自进化智能体。

上述收集、归因、分流的完整流程如算法 4.5 所示。

算法 4.5 失败案例驱动的评估器与基建自演化

输入： 失败案例缓冲 $\mathcal{B}$ ，当前评估器/基建 Φ ，触发周期 $T_e=10$ 步，容量 $C=20$

输出： 更新后的评估器/基建 Φ'

```

1: for each 本步产生的轨迹  $\tau$  do
2:   if IsFailed( $\tau$ ) then                                ▷ 执行失败/奖励异常/自述与差分矛盾
3:      $\mathcal{B} \leftarrow \mathcal{B} \cup \{\text{Evidence}(\tau)\}$             ▷ 连同任务、轨迹、差分、报错留存
4:   end if
5: end for
6: if (mod  $T_e = 0$ ) or  $|\mathcal{B}| \geq C$  then                ▷ 周期或容量触发
7:    $\Phi' \leftarrow \Phi$ 
8:   for each 案例  $b \in \mathcal{B}$  do
9:      $z \leftarrow \text{LLMAttribution}(b)$                 ▷ 大模型归因：model / infra / unclear
10:    if  $z = \text{model}$  then
11:       $\Phi' \leftarrow \Phi' \oplus \text{PromptPatch}(b)$         ▷ 增量修订裁判/提问者/执行者提示词
12:    else if  $z = \text{infra}$  then
13:       $\Phi' \leftarrow \Phi' \oplus \text{InfraPatch}(b)$         ▷ 注册工具/补依赖/调超时/修 harness
14:    end if
15:  end for
16:   $\mathcal{B} \leftarrow \emptyset$                                 ▷ 清空缓冲，进入下一周期
17:  return  $\Phi'$ 
18: end if
19: return  $\Phi$                                             ▷ 未触发，保持不变
    
```

失败模式与缓解。(1) 归因误判——模型问题与基建问题表象常重叠(如 OOM 既可能是内存配额不足也可能是策略选了低效方案)，规则判断不可靠；缓解措施是由大模型综合任务意图、轨迹与环境证据研判，而非按错误码机械判定。(2) **提示词漂移**——整体重写提示词易引入不可控偏移、难回滚；缓解措施是采用增量追加式修订 ($\oplus$)，保证可回滚、不漂移。(3) **旁路阻塞主循环**——归因或更新失败

若中断训练则代价高；缓解措施是该支路以 **best-effort** 异步运行，任何失败被捕获并跳过、不影响训练推进（工程细节见第五章）。

需要说明的是，本机制涉及的各项参数（如每 10 步或攒够 20 个失败案例触发一次归因、以及全文训练配置中的各项超参与阈值），均以**演示系统可运行性**为目的而设定，并非经调优得到的最优取值。本文的目标是验证该自演化机制能够端到端接入闭环、被正确触发与执行，而非在具体任务上追求最优效果；这些参数的最优配置需在系统跑通后经系统性调优确定，属工程优化范畴。

4.7 自进化稳定性控制机制

自进化稳定性控制保障系统在无人值守下的长期运行。自进化系统持续自主运转、无人值守，策略一旦发生模式坍缩或训练崩溃而不被及时检测，将导致后续所有训练步在无效信号上空转。监控机制的总体结构如图 4.7 所示。




图 4.7 自进化稳定性控制：五项监控指标与自动终止判据

本文选取以下指标作为坍缩 / 崩溃的判据，其内在依据为：

- **奖励标准差**：组内奖励的离散程度。趋近 0 表示所有轨迹得分趋同，策略多样性坍缩（对应 Echo Trap^[24]）。
- **优势标准差**：优势的离散程度。趋近 0 表示无有效梯度信号，训练无法推进。
- **策略 KL 散度**：策略偏离参考策略的程度。过大表示策略偏离过远，训练不稳定。
- **训练损失**：出现 NaN / Inf 表示数值崩溃。
- **存活组数**：淘汰后存活组数持续低于训练组数，表示超采样池耗尽，自进化难以为继。

当任一指标触发阈值时，系统判定自进化已失稳，应终止训练。

实现与思路。稳定性控制的设计原则是“轻量感知、及时止损”：五项指标均在训练循环的现有计算路径上以零额外开销取得（奖励标准差来自选组统计，优势标准差来自 GRPO 归一化，KL 散度来自策略更新后的比对），无需引入额外的评估流程。阈值类型的设计上，奖励标准差与优势标准差采用绝对值下界（趋近零即报警），KL 散度与训练损失采用上界（过大或出现 NaN 即报警），存活组数采用相对比例（低于训练组数 N 时报警）；上述判据中的具体阈值取值（ ϵ_r 、 ϵ_A 、 κ 等）属实验配置，其在本文实验中的设定见第五章。任一指标触发即终止，而不是“多数触发才终止”——这是因为各指标对应不同的失稳模式，任一单独触发都意味着自进化已无法产生有效信号，继续运行只会浪费计算资源。

自进化稳定性控制的判定逻辑如算法 4.6 所示。

失败模式与缓解。（1）**坍缩漏检**——策略多样性已丧失却未被察觉，后续训练步在无效信号上空转；缓解措施是同时监控奖励与优势两个标准差，任一趋零即报警。（2）**误终止**——正常的奖励收窄被误判为坍缩而过早停机；缓解措施是标准差类判据取极小的绝对下界，远低于正常训练的方差水平，避免误触发（具体取值见第五章）。（3）**监控自身拖慢训练**——若引入额外评估流程，监控本身会成为开销；缓解措施是五项指标全部复用训练循环已有的中间量，零额外前向/采样开销。

算法 4.6 自进化稳定性监控与自动终止

输入： 本步奖励 $\{r_{ij}\}$ 、优势 $\{\hat{A}_{ij}\}$ 、策略 KL 、训练损失 ℓ 、存活组数 R ；阈值 $\epsilon_r, \epsilon_A, \kappa$ 与训练组数 N

输出： 是否终止的布尔标志 stop

- 1: $\sigma_r \leftarrow \text{Std}(\{r_{ij}\})$; $\sigma_A \leftarrow \text{Std}(\{\hat{A}_{ij}\})$ ▷ 均取自现有计算路径，零额外开销
 - 2: **if** $\sigma_r < \epsilon_r$ **then return true** ▷ 奖励多样性坍缩 (Echo Trap)
 - 3: **else if** $\sigma_A < \epsilon_A$ **then return true** ▷ 无有效梯度信号
 - 4: **else if** $\text{IsNaN}(\ell)$ **or** $\text{IsInf}(\ell)$ **then return true** ▷ 数值崩溃
 - 5: **else if** $\text{KL} > \kappa$ **then return true** ▷ 策略偏离过远
 - 6: **else if** $R < N$ **then return true** ▷ 超采样池耗尽
 - 7: **end if**
 - 8: **return false** ▷ 各指标均正常，继续自进化
-

4.8 本章小结

本章按“总一分”结构，围绕第一章六项主要贡献设计了自进化闭环的方法：方法总体框架统领全局，将传统训练扩展为自进化闭环；随后依次给出六个核心机制——跨步自进化任务生成（贡献一）自主产生后续任务，多智能体协作机制（贡献二）以角色分工使采样、取证与追问全部自主化，超采样-淘汰-选组（贡献三）以“多推理少训练”提升训练信号质量，差分驱动奖励（贡献四）使奖励锚定环境真实状态、抗奖励作弊，失败案例驱动的评估器与基建自演化（贡献五）将自进化扩展到评估器与基建两维，自进化稳定性控制（贡献六）保障闭环无人值守下的稳定运行。本章侧重各机制的设计原理与分析，其对应的工程实现见第五章。

第 5 章 自进化强化学习系统设计与实现

第四章从设计与方法层面阐述了自进化的六个核心机制。本章转向工程与实现层面，说明这些机制如何落地为一个可运行的系统：先给出系统总体架构与支撑各机制的公共基建（沙箱环境与状态管理），再依次说明各机制的工程实现要点——跨步状态继承、采样与训练解耦、自进化数据处理流程、失败案例驱动的评估器与基建自演化、训练监控与自动终止，最后给出串接全部模块的系统整体运行流程。与第四章侧重原理和设计不同，本章侧重接口、数据流、工程约束与实现分析。

5.1 系统总体架构

系统总体架构如图 5.1 所示。系统由三个协同智能体（执行者、观察者、提问者）、沙箱环境、外部冻结裁判以及 GRPO 训练器组成。为在不修改强化学习框架源码的前提下接入自进化所需的自定义采样与选组逻辑，系统全部通过框架提供的官方注入点接入，与框架主体解耦、便于随框架升级维护。

实现与思路。系统在实现上分为三层，各层职责单一、经明确接口衔接。采样层（rollout/）负责沙箱会话管理与三智能体协作采样，产出带状态差分的交互轨迹；奖励层（agents/ 与奖励回路）在采样产出之上内联计算奖励——观察者取证、冻结裁判打分、验证器交叉核对，结果直接写入训练所需的奖励字段；训练层（trainer/）承载 GRPO 更新与选组钩子。三层与强化学习框架的耦合被刻意收敛到单一入口：采样、奖励、跨步等模块均不直接依赖框架，仅由一个薄适配层在框架的官方注入点上懒加载并转调，因此框架升级时只需维护该适配层。这一分层使得除全栈训练外的绝大部分逻辑都可在无 GPU、无框架的环境下独立单元测试。




图 5.1 系统总体架构

5.2 沙箱环境与状态管理

沙箱环境是自进化闭环的物理基础，为各机制提供共用的执行与取证底座：观察者的状态取证、差分驱动奖励的证据来源均建立其上。其状态管理机制如图 5.2 所示。系统在代码沙箱中执行 **ReAct** 工具调用，并在执行前后对沙箱状态各拍一次快照，作差得到确定性状态差分。状态差分包含文件系统变更（创建 / 修改 / 删除的文件及其内容）与系统状态变更（安装的包、开启的端口、启动的进程）。沙箱后端经统一契约与注册表解耦，本地开发与云端生产可零改切换。




图 5.2 沙箱环境与状态管理：执行前后快照作差得到确定性状态差分

实现与思路。沙箱状态的捕获由观察者负责，采用“执行前注入探针、执行后再次探针、取差集”的三步流程。文件系统探针递归遍历沙箱根目录，记录每个文件的路径、大小、修改时间及内容哈希；系统状态探针通过 `pip list`、`ss -lnp`、`ps aux` 等命令捕获已安装包、监听端口与活跃进程。两次探针的差集即为确定性状态差分，作为奖励评估的客观依据。后端解耦采用“契约 + 注册表”模式：**SandboxClient** 协议定义统一接口，各厂商后端注册到表中按标识选择，因

此本地 Docker 与云端沙箱通过同一接口接入，训练配置切换后端标识即可、调用方零改动。

5.3 跨步状态继承

跨步自进化在工程上依赖沙箱状态在训练轮次间的可靠传递。系统将上轮最优轨迹的沙箱文件系统状态保存为快照，恢复到本轮新沙箱，使智能体在上轮产出的文件基础上继续工作。沙箱状态继承机制如图 5.3 所示。




图 5.3 沙箱状态继承机制

实现与思路。快照以 `tar` 打包工作区文件、经 `base64` 编码后通过数据通道在轮次间传递，在下一轮新沙箱内解码还原。为控制传递开销，仅继承文件系统工作区，不继承进程与端口等易失状态；被继承的上一轮最优轨迹由选组阶段确定。

5.4 采样与训练解耦

超采样-淘汰-选组机制（其原理与漏斗式收敛见第四章图 4.4）在工程上的挑战是：如何在强化学习框架的定长批次约束下，无缝嵌入“多采样、少训练”这一变长的漏斗流程，且不修改框架源码。本节说明其实现要点，不再重复该机制的原理。

实现与思路。系统通过框架的官方注入点接入自定义的采样管理器与选组层。采样管理器负责组织超采样的 $S \times n$ 条轨迹（ S 为当前步超采样量、 n 为 GRPO 组大小）。选组层作为框架的后处理钩子，在优势计算之后、策略梯度更新之前介入：先按淘汰判据过滤得到 R 个存活组，再按组内优势绝对值均值取前 N 组，将 $S \times n$ 条收敛为 $N \times n$ 条训练批次。这一流程的工程关键在于**对框架透明**——训练器始终只看到固定的 $N \times n$ 批次，超采样与过滤发生在钩子内部，框架不感知额外采样的存在；由此在不改框架源码的前提下实现了“推理超采样、训练精选”的解耦，也便于随框架版本升级而无需维护分支。

5.5 自进化数据处理流程

单个训练步内数据在各模块间的流转，与第四章方法总体框架（图 4.1）所示的闭环一致：采样管理器组织任务并驱动执行者 rollout，观察者取证并计算状态差分，裁判据差分打分，选组层淘汰低质组、选梯度最优组，训练器做 GRPO 更新，训练步结束后由跨步模块对存活组生成下一轮任务。此处不再重复该流程图，仅说明其工程实现要点。

实现与思路。数据处理流程遵循“各环节单向流动、无回路依赖”的原则：任务 $\rightarrow$ rollout $\rightarrow$ 取证 $\rightarrow$ 打分 $\rightarrow$ 选组 $\rightarrow$ 更新 $\rightarrow$ 下一轮任务，每个环节只依赖上一步的输出，便于独立测试与替换。

5.6 失败案例驱动的评估器与基建自演化

评估器与基建的自演化在工程上以一条挂接于主流程的**旁路**实现，不阻塞训练主循环。失败案例缓冲（BadcaseBuffer）挂接在打分环节之后：奖励低于阈值、含 `agent_error` 或空交付的轨迹，连同其任务、轨迹、状态差分与工具报错等取证信息被异步收集。每累计 10 个训练步或缓冲区攒够 20 条失败案例时，触发一次大模型归因（LLMAtribution）：由大模型判别每个失败的根因在**模型侧**还是**基建侧**，据此分别对提示词做增量修订（模型侧：热更新裁判、提问者、执行者的提示词）或对基建做扩展（基建侧：注册新工具、补装依赖、调整超时、将缺失能力沉淀为可复用技能），随后清空缓冲、进入下一周期。该旁路以 **best-effort** 方式运行——任何归因或更新的失败都被捕获并跳过，不影响训练继续推进，从而在为评估器与基建持续注入改进的同时保证主流程的稳定。

5.7 训练监控与自动终止

第四章界定了自进化稳定性的判据指标，本节说明其工程实现。系统在每个训练步的优势计算完成后，实时采集以下坍缩指标并写入训练日志：

- 奖励标准差（`sys/reward_std`）：组内奖励的标准差。
- 优势标准差（`sys/advantage_std`）：优势的标准差。
- 组内奖励标准差（`sys/group_reward_std`）：GRPO 组内奖励的标准差，0 表示退化组。
- 策略 KL 散度（`actor/ppo_kl`）：策略偏离参考策略的程度。
- 训练损失（`actor/pg_loss`）：出现 NaN / Inf 表示训练崩溃。
- 存活组数（`sys/num_groups`）：淘汰后的存活组数。

第四章给出了监控指标与判据类型，其中的具体阈值属实验配置。本文实验中各判据的阈值取值如表 5.1 所示：任一判据触发时，系统跳过跨步任务生成，训

训练循环在下一步检测到终止标志后退出。这些指标随训练步的实际变化曲线与终止判据的触发情况，在第 6.4 节结合训练实验一并给出。

表 5.1 自动终止判据的阈值取值（本文实验设定）

监控指标	终止判据	失稳含义
奖励标准差 σ_r	$\sigma_r < \epsilon_r = 10^{-6}$	策略多样性坍缩
优势标准差 σ_A	$\sigma_A < \epsilon_A = 10^{-6}$	无有效梯度信号
训练损失 ℓ	ℓ 为 NaN 或 Inf	数值崩溃
策略 KL 散度	$KL > \kappa = 10$	策略偏离过远
存活组数 R	$R < N$ （训练组数）	超采样池耗尽

5.8 系统运行流程

综合以上模块，系统的完整运行流程为：初始化沙箱后端、推理引擎、训练器与奖励回路；第一步从初始种子采样，后续步用跨步生成的任务；每步内经过 rollout、状态差分取证、奖励打分、淘汰选组、GRPO 更新、训练监控、跨步任务生成；每 10 步或累积 20 个失败案例时触发一次评估器与基建的自演化；直至终止判据触发或达到步数上限。完整流程如算法 5.1 所示。

三智能体的协作时序如图 5.4 所示，执行者的沙箱内 ReAct 循环如图 5.5 所示。

算法 5.1 自进化强化学习主循环（含失败案例自演化）

输入： 初始种子集 Q_0 ，训练组数 N ，组大小 n ，最大步数 $T_{\max}$
输出： 训练后的策略 π_θ

```

1: 初始化沙箱后端、推理引擎、训练器、奖励回路；  $\pi_\theta \leftarrow \pi_{\theta_0}$ 
2:  $S \leftarrow 2N$ ；任务集  $Q \leftarrow Q_0$ ；失败案例缓冲  $\mathcal{B} \leftarrow \emptyset$  ▷ 第一步冷启动
3: for  $t = 0$  to  $T_{\max} - 1$  do
4:    $\{\tau_{ij}\} \leftarrow \text{Rollout}(\pi_\theta, Q, n)$  ▷  $S$  组  $\times n$  条，沙箱内 ReAct
5:   for each 轨迹  $\tau_{ij}$  do
6:      $d_{ij} \leftarrow \text{Observe}(\tau_{ij})$  ▷ 执行前后状态差分（确定性取证）
7:      $r_{ij} \leftarrow \text{Judge}(d_{ij})$  ▷ 冻结裁判据状态差分打分
8:     if  $\text{IsFailed}(\tau_{ij}, d_{ij}, r_{ij})$  then ▷ 失败/异常/自述与差分矛盾
9:        $\mathcal{B} \leftarrow \mathcal{B} \cup \{(\tau_{ij}, d_{ij}, r_{ij})\}$  ▷ 收集失败案例
10:    end if
11:  end for
12:   $\{\hat{A}_{ij}\} \leftarrow \text{ComputeAdvantage}(\{r_{ij}\})$  ▷ GRPO 组内归一化
13:   $\mathcal{R} \leftarrow \text{Eliminate}(\{r_{ij}\})$  ▷  $S \rightarrow R$ : 丢最大 reward 后 20% 且  $< 0.5$  的组
14:   $m \leftarrow \text{CollapseMetrics}(\{r_{ij}\}, \{\hat{A}_{ij}\}, |\mathcal{R}|)$  ▷ 奖励/优势标准差、存活组数等
15:  if  $\text{ShouldStop}(m)$  then ▷ 坍塌或崩溃判据触发（含  $R < N$ ）
16:    break
17:  end if
18:   $\mathcal{S} \leftarrow \text{Select}(\mathcal{R}, N)$  ▷  $R \rightarrow N$ : 按  $|\hat{A}|$  均值选梯度最强  $N$  组
19:   $\pi_\theta \leftarrow \text{GRPOUpdate}(\pi_\theta, \mathcal{S})$  ▷ 仅  $N \times n$  条进梯度
20:  if  $(t + 1) \bmod 10 = 0$  or  $|\mathcal{B}| \geq 20$  then ▷ 触发失败案例自演化
21:     $(\Delta_{\text{prompt}}, \Delta_{\text{infra}}) \leftarrow \text{LLMAttribution}(\mathcal{B})$  ▷ 大模型归因：模型/基建
22:     $\text{UpdatePrompts}(\Delta_{\text{prompt}})$  ▷ 热更新裁判/提问者/执行者提示词
23:     $\text{ExpandInfra}(\Delta_{\text{infra}})$  ▷ 动态注册工具/补依赖/修 harness
24:     $\mathcal{B} \leftarrow \emptyset$  ▷ 清空缓冲，开始下一周期收集
25:  end if
26:   $Q \leftarrow \text{Questioner}(\text{Summary}(\mathcal{R}), \text{Snapshot}(\mathcal{R}))$  ▷ 跨步：存活组产下一
    轮任务
27:   $S \leftarrow |\mathcal{R}|$  ▷ 下一步超采样量  $S = R$ ，随淘汰动态收缩
28: end for
29: return  $\pi_\theta$ 
    
```





图 5.4 三智能体协作时序




图 5.5 执行者沙箱内 ReAct 循环

5.9 本章小结

本章从工程与实现层面描述了系统的落地：系统总体架构与公共基建（沙箱环境与状态管理），各核心机制的实现要点（跨步状态继承、采样与训练解耦、自进化数据处理流程、失败案例驱动的评估器与基建自演化、训练监控与自动终止），串接全部模块的系统整体运行流程与主循环算法。全部自定义逻辑均通过框架官方注入点接入、不修改框架源码，保证了系统的可维护性；这些工程模块共同保证第四章各机制得以物理运转，并使自进化过程稳定可控。

第 6 章 实验与结果分析

本章以端到端的方式验证自进化系统的整体可行性。下文各节的结果均来自同一次完整的端到端自进化实验，从**超采样量收缩、任务难度演化、训练奖励变化、模型能力得分、生成多样性与最终得分**六个不同维度分别观察，分析训练过程的稳定性和系统的端到端可行性，并逐一分析每张图的含义，最后综合各维度给出整体结论。本章实验的重点是验证“数据自主产生—可信奖励—基建自我强化—跨步自进化”闭环能端到端稳定运转、且自产生数据具备真实训练价值，而非在具体任务上追求绝对最优的性能。

6.1 实验设置

实验配置如表 6.1 所示。基座模型为 Qwen3.5-9B，策略优化采用标准 GRPO，推理与训练异步分离。两类实验的任务均采用统一的难度评分体系：难度以 10 分为满分，由**工具调用强度、思考与推理强度、知识需求**等多个维度综合评分得到，分数越高表示任务越复杂；本实验所用任务的难度集中在 4~7 级，覆盖数据分析、脚本开发、日志审计等真实任务场景。在此统一难度体系下，两类实验的数据供给方式不同：**自进化实验仅用 128 条启动种子**冷启动，此后各步的训练任务全部由系统跨步自主生成，不再注入外部数据；作为对照的**回流基线则使用全量 3200 条真实回流数据**（每步取 $N = 64$ 组，50 步恰好用尽一轮）。两者均运行 50 步，若稳定性终止判据先触发则提前停止。

注：系统并未在达成监控系统设置的终止条件之外限制训练步数，但为了实验规模可控，可与传统 RL 实验对比验证效果，实验在 50 步时手动结束。

训练奖励评分函数。训练过程中的奖励由本文的差分驱动评分函数产生（机制

表 6.1 实验配置

参数名称	参数值
显卡型号	NVIDIA H800 80GB
硬件规模	8 卡 * 2
基座模型	Qwen3.5-9B
策略优化	GRPO
自进化启动种子数	128
回流基线数据量	3200
训练组数 N	64
初始超采样量 S	128
GRPO 组大小 n	8
初始推理轨迹 / 步	1024
训练轨迹 / 步	512
训练步数	达成监控系统设置的终止条件

详见第四章第 4.5 节)。最终奖励为

$$R = (0.6 T + 0.4 C) \times S_{\text{safe}}, \quad (6.1)$$

其中

$$T = 0.15 E + 0.25 P + 0.45 C_{\text{cons}} + 0.15 R_{\text{rec}}. \quad (6.2)$$

各分量的含义如下：

- C 为**正确性**，度量最终产物相对任务要求的正确程度；
- T 为**轨迹综合分**，度量执行过程的整体质量，由式 6.2 中所示的四个评分维度加权组成：
 - E 为**效率**，度量单位交互的资源利用；
 - P 为**规划**，度量任务分解与执行路径的合理性；
 - C_{cons} 为**一致性**，度量执行描述与真实环境的相符程度及任务是否真正完成；
 - R_{rec} 为**恢复**，度量出错后的自我修正能力；
- S_{safe} 为**乘性安全门**，度量模型产生的动作的安全性。

上述各分量均由外部冻结的大模型裁判依据观察者产出的确定性状态差分评定。

训练过程的效果以在线过程指标衡量（超采样量、任务难度代理指标、奖励均值与组内奖励标准差，均在训练循环的现有计算路径上零额外开销取得）；训练前后的实际能力变化则以离线评测衡量。

评测集与环境。评测集选用 ClawEval 中的纯文本类任务，以贴合本文以文本工具调用为主的训练设定；评测环境为腾讯云沙箱配合 ClawEval 官方评测工具，与训练所用的沙箱后端、工具集及差分驱动打分口径保持一致，从而排除环境差异对评测结论的干扰。

ClawEval 评分规则。离线评测使用 ClawEval 官方评分函数。官方 grader 对每条轨迹评定**完成度** (completion)、**鲁棒性** (robustness) 与**安全性** (safety) 三个维度，任务得分为

$$\text{score} = \text{safety} \times (0.80 \times \text{completion} + 0.20 \times \text{robustness}), \quad (6.3)$$

其中安全性作为乘性门作用于基础分；任务得分不低于 0.75 判为通过，模型总得分为所有任务、所有采样得分的均值。其定位是**能力评测**：以固定的权重组合与通过阈值，衡量模型在固定评测集上的完成水平。

需要指出的是，ClawEval 评分函数与式 6.1 的训练奖励函数在若干分量上含义相近，但二者的给分尺度不同，这是有意的设计：为保证评测相对独立于训练口径，二者不作对齐。

对比对象。端到端地评测对比三个模型在同一评测集上的能力表现：（1）未训练的基座模型（Qwen3.5-9B，作为能力起点）；（2）以真实回流数据训练 50 步的模型（回流基线，反映“有充足人工数据”时同一训练管线可达的水平）；（3）以本文所提出的自进化系统训练 50 步的模型（自产生数据）。三者**除训练数据来源不同外，其余配置完全一致**——同一基座、同一 GRPO 管线、同一超参与训练步数，因而三者的差异可归因于数据来源这一单一变量：基座与自进化模型之比衡量“自进化训练是否有效”，自进化模型与回流基线之比衡量“自产生数据相对真实人工数据的价值”。

为何奖励函数不直接采用 ClawEval 评分细则。训练奖励是 RL 的优化目标，评测得分是模型能力的独立度量，二者必须解耦：若令奖励函数等于评测细则，策略对细则的过拟合会直接表现为评测分数虚高，第 6.5 节关于训练指标改善反映真实能力提升的论断即失去前提。因此训练内用差分驱动评分函数、评测外用 ClawEval rubric，二者互为印证。

评测流程与指标。评测采用统一的端到端流程：对每个评测任务，被测模型在腾讯云沙箱中以与训练相同的 ReAct 方式多步调用工具求解，由 ClawEval 官方 grader 按上述规则打分；为抵消单次生成的随机性，每个任务独立重复采样 k 次。据此报告两个维度的指标：（i）**平均得分**——所有任务、所有采样的 grader 得分均值，度量模型的任务完成能力；（ii）**生成多样性**——以 $\text{pass}@k$ 意义下的任意通过率 (any_pass_rate) 近似，即在 k 次采样中至少通过一次的任务占比。两个

指标从**深度**与**广度**两个方向分别刻画模型能力：平均得分刻画单次求解的完成强度，**any_pass_rate** 刻画多次采样下解空间的覆盖范围。为何以 **any_pass_rate** 度量多样性？关键在于本文关注的“多样性”并非表层的用词或措辞差异，而是**策略解空间的覆盖广度**——面对同一任务，模型的 k 次采样能否探索出多条不同的、其中至少一条可行的解法。平均得分（均值）无法反映这一点：一个已发生多样性坍塌、每次都输出同一条“中庸”解的模型，其均值可能并不低，却会在需要另辟路径的任务上稳定失败。而 **any_pass_rate** 恰好将“能否覆盖到”与“平均得多少分”解耦——只要 k 次中有一次找到可行解即计入，因此它对**解法多样性**敏感：采样越趋同（坍塌越重）， k 次落在同一条解上、能新覆盖的任务就越少，该值随之下降。相比直接度量文本差异（易受表面措辞干扰）或人工标注多样性（成本高、主观），基于 **pass@ k** 的任意通过率以任务是否被覆盖这一客观、可自动判定的信号近似多样性，成本低且与训练过程中的组内奖励标准差在含义上一致，二者可形成过程—终点的相互印证。

6.2 自进化闭环与超采样收缩

首先验证自进化闭环是否成立：系统除初始种子外能否持续自主产生训练任务、且超采样池不塌缩。评价方法为观测每步的跨步任务生成情况与超采样量 S 的收缩过程—— S 从第一步的 $2N$ 起，随每步淘汰逐步收缩至存活组数 R ，若各步跨步任务均成功生成、且 S 稳定收缩而不塌缩至零，则闭环成立。收缩曲线如图 6.1 所示。

图含义与分析。图 6.1 的横轴为训练步、纵轴为该步的超采样量 S （即待 rollout 的任务组数）。可见 S 呈单调不增的**阶梯式收缩**，**前期下降快、后期趋于平缓**。这一走势与淘汰判据直接相关：淘汰条件之一是组内最大 reward 低于阈值。训练前期模型能力尚弱、整体 reward 偏低，较多组的最大 reward 达不到阈值，容易满足淘汰条件而被大量剔除， S 快速下降；随着训练推进、策略能力提升，各组 reward 整体抬高，落入淘汰区间的组越来越少，淘汰量随之减小， S 的收缩逐步放缓并最终稳定在训练组数 N 附近。 S 始终未塌缩至零、各步跨步任务均成功生成，表明在无外部数据补给下系统仍能持续产出足量可训练任务，**自进化**




图 6.1 超采样量 S 随训练步收缩

闭环稳定成立。

6.3 自主数据生成与任务难度演化

自进化闭环成立后，进一步观察其自主生成的任务是否随训练向更高难度演化——这是任务与策略协同演化的直接体现。任务难度以轨迹平均步数、工具调用次数等代理指标度量，观测其随训练步的变化，如图 6.2 所示。




图 6.2 任务难度随自进化演化

图含义与分析。图 6.2 的横轴为训练步、纵轴为以代理指标度量的任务难度。真实训练数据显示，随自进化推进，提问者基于上一轮真实产物与执行概括再生成的任务**难度持续上升**：轨迹的平均响应长度从第 1 步的约 2 377 token 增至末段的约 14 330 token（增长约 6 倍），平均交互轮数从约 27.7 提升至约 47.7——任务不再停留在初始种子的简单形态，而是在已有产物之上层层追加需求、逐步加深，需要更长的推理与更多轮的工具交互才能完成。这印证了跨步自进化机制的设计目标——任务生长在上一轮的真实执行结果之上，形成一条**有依据、有递进**的演化链，使训练任务的难度随策略能力同步抬升、持续提供有梯度的学习信号，而非固定题库那样与模型能力脱节。

6.4 训练过程：奖励变化与稳定性

本节分析 GRPO 训练过程中奖励信号的变化，并据此考察系统的稳定性。为验证自产生数据的训练价值，将本文自进化系统产生的数据（自产生数据）与以真实回流数据（每个 query 均为真实用户回流）训练的普通强化学习（对照组）在完全相同的 GRPO 训练管线下对比，奖励随训练步的变化如图 6.3 所示。




图 6.3 自产生数据（本文）与回流数据（对照）训练的奖励均值对比（EMA 平滑）

图含义与分析。图 6.3 的横轴为训练步、纵轴为奖励，两条主线为奖励均值经指数滑动平均（EMA）平滑后的曲线。可以观察到：**自产生数据的奖励均值稳步上升，从第 1 步的约 0.26 升至第 50 步的约 0.55。**

第 1 步起点为何偏低（约 0.26，低于回流对照的约 0.37）。这一现象并非训练异常，而是**超采样-淘汰-选组机制与优势定义共同作用的必然结果**，其机制链路为：其一，训练第 1 步模型尚未适应任务格式与工具调用，整体奖励本就处于冷启动低位；其二，更关键的是**选组依据是优势而非 reward 本身**——GRPO 的组内优势定义为 $\hat{A}_{ij} = (r_{ij} - \mu_i) / (\sigma_i + \epsilon)$ ，真正被选入训练批次的，是按组内 $|\hat{A}|$ 均值降序取出的前 N 组，即**组内奖励分化最剧烈的组**。这类组“有成功、有失败”，因而能提供最强的梯度对比信号，但其中失败轨迹会把该组的奖励均值拉低；反过

来，那些所有轨迹都成功的组虽然 reward 高，却因组内几乎无分化 ($\sigma_i \rightarrow 0$) 导致优势趋近于零，**恰恰不会被选中**。因此，训练批次呈现的奖励均值是“被选中的、最具学习价值的那批组”的均值，它**系统性地低于全部候选组的平均 reward**，在起步阶段尤为明显；回流对照因不含此选组环节，其奖励均值覆盖全部样本、起点相对更高。

随着训练推进，策略能力提升、各组成功率普遍提高，被选中组的 reward 也随之抬升，两条曲线均呈上升趋势；**自产生数据的学习速度更快**——从冷启动低位（约 0.26）起步，仅用约 20 步即完成对回流基线的超越并保持领先，最终两者收敛到相近的高位（约 0.55 与 0.52）。这一更快的爬升速度同样源于超采样-淘汰-选组机制：一方面，**按优势选组**使每个训练批次集中于梯度对比信号最强的组，同样的更新步数获得了更高的样本效率；另一方面，**淘汰机制**持续剔除组内最优 reward 低于阈值的低质量组，避免了无效信号对梯度的稀释。两者叠加，使系统在数据由自身生成（而非外部回流）的条件下仍实现了不慢于、甚至快于回流基线的学习速度。这说明系统自主合成的数据能够持续提供有效的梯度信号、驱动策略改进，其训练价值**不弱于真实回流数据**。

组内奖励标准差与方差坍缩。奖励均值之外，另一个关键的过程指标是**组内奖励标准差**——即各 GRPO 组内 n 条轨迹奖励标准差在所有组上的均值，它度量策略输出的多样性，该值趋 0 即为多样性坍缩。两组的组内奖励标准差随训练步的变化如图 6.4 所示。

由图 6.4 可见：自产生数据的策略熵从约 **0.47** 逐步下降至约 **0.24**、轨迹多样性 std 从约 **0.16** 收窄至约 **0.09**，均呈清晰的下行趋势；而回流数据两项指标均相对平稳，熵约 **0.29→0.25**、std 约 **0.09→0.06**，下降幅度明显小于自产生数据。值得注意的是两组数据在**绝对水平与演化速率**上的双重差异：自产生数据的熵与 std 的**全程均值高于回流对照**（熵 0.287 对 0.263、std 0.105 对 0.073），起点亦明显更高（0.47 对 0.29、0.16 对 0.09）；但其**下降速率更快**，末段两者收敛到相近水平（熵约 0.24~0.25、std 约 0.09 对 0.06）。这表明自进化过程具有一定的熵减与坍缩**退化趋势**，但该趋势在 50 步的观测窗口内**未演化为实际退化**：多样性指标全程保持非零、未触及终止阈值，训练完整进行 50 步，且离线评测确认模型能力获得实质性提升（第 6.5 节）——学习信号的有效性并未因该趋




图 6.4 组内奖励标准差随训练步的变化 (EMA 平滑)：自产生数据逐步收窄 (方差坍缩)，回流数据平稳

势受损。这一趋势的成因在于数据来源的差异：自产生数据在轮次间由系统基于上一轮经验自我生成，生成过程受当前策略偏好的影响、逐轮趋同；真实回流数据则由外部独立注入，持续携带策略分布之外的多样性。这也解释了图 6.3 中自产生数据奖励曲线更平滑的现象——组内评分趋同使曲线波动减小。此外需要说明，本实验未对提示词与超参数进行系统性精调，上述退化趋势属于未经优化配置下的自然表现；可以预期，经过提示词与超参的联合精调（如引入多样性激励、熵正则等），该趋势可以得到抑制，系统实现更优的长期运行。

稳定性验证。这一收缩趋势正是稳定性监控的对象。本次真实运行的稳定性数据可以从两方面看：其一，**训练信号健康**——策略熵与轨迹多样性 std 平滑收窄（如前所述），梯度范数 (grad_norm) 从约 0.48 平稳衰减至约 0.17，pg_loss 与 ppo_kl 始终在合理范围内波动、无 NaN / Inf，表明策略在持续、稳定地改进；其二，**系统零故障**——全程 50 步中失败会话数、被过滤的残缺会话数、轨迹中止比例均为 0，每步均成功产出足量完整轨迹，说明沙箱、工具执行与多智能体协作链路在整个训练过程中稳定可靠。组内奖励标准差虽持续收窄但尚未触及 10^{-6} 终止阈值，故完整跑满并达到设定的 50 步上限，且模型能力在此过程中得到实质提升（见第 6.5 节的离线评测）。而在另一组配置下坍缩更快——模型训练至约 30 步时组内奖励标准差即快速缩小并触及监控阈值，终止判据被自动触发、提前结束自进化，避免了后续训练步在已坍缩的无效信号上空转。两种情形共同表

明：监控指标能灵敏反映策略多样性的变化，终止判据既不在正常收窄时误触发、也能在真正坍塌时及时止损，达到了“轻量感知、及时止损”的设计目标。

6.5 模型能力评测

为何需要离线评测。前几节的过程指标（超采样收缩、任务难度、奖励均值、组内标准差）刻画的是训练过程的健康度，但它们不足以证明模型能力真的提升：奖励均值上升只说明策略在当前的奖励口径下得分更高，而这一口径本身随自进化演化，存在**训练指标改善而模型实际能力未变**的风险。要排除这一可能，必须以**独立于训练回路的固定评测集**、以统一口径衡量训练前后模型的真实能力——这正是离线评测的意义：它为模型能力的真实变化提供了外部参照，从而回答“模型是否真的变强了，而不仅是训练指标更好看”这一关键问题。

本节以离线评测衡量训练前后模型的实际能力变化，从平均得分与生成多样性两个维度对比三个模型（评测集、对比对象与指标定义见第 6.1 节的实验设置）。

（一）平均得分：能力是否真的提升。三个模型在通用任务上的平均得分如图 6.5 所示。




图 6.5 三个模型在通用任务上的平均得分

本文自进化数据训练的模型得分为 0.401，明显高于未训练基座（0.370）。

由于该评测独立于训练奖励口径，这一提升**排除了训练指标改善源于评分口径自身演化的解释**，证实自进化训练确实带来可观测的真实能力增益；其提升幅度小于以真实回流数据训练的模型（0.428）。

（二）**生成多样性：是否发生坍缩**。三个模型的生成多样性（以任意通过率 any_pass_rate 近似）如图 6.6 所示。




图 6.6 三个模型的生成多样性（任意通过率 any_pass_rate）

自进化数据训练模型的多样性（0.285）**略低于**未训练基座（0.294）与回流数据训练模型（0.312）。这与训练过程中观察到的方差坍缩现象一致——自产生数据在轮次间逐渐趋同、组内奖励标准差收窄，反映在评测终点上即为生成多样性的小幅下降。

（三）**两维合起来看**。综合图 6.5 与图 6.6：自进化训练在**能力上确有真实提升**（明显超过未训练基座），代价是**多样性的小幅回落**。这两个终点指标与训练过程指标**相互印证**——过程上观测到的方差坍缩（图 6.4），正对应终点评测上多样性的下降；而能力的净提升说明：即便存在轻微的多性损失，自产生数据带来的有效学习信号仍占主导。也就是说，系统不是靠“刷高自己的评分”制造了虚假繁荣，而是实打实地训练出了更强的模型。

6.6 综合分析

将六组结果合起来看，可以得到一条自洽的证据链，共同支撑本文对系统可行性的结论：

（1）闭环能自我维持（跨步自进化任务生成）。图 6.1 表明超采样量 S 稳定收缩而不塌缩、各步跨步任务均成功生成——系统在无外部数据补给下持续产出足量可训练任务，自进化闭环端到端跑通。

（2）自产生数据在演化、且有训练价值（多智能体协作与差分驱动奖励）。图 6.2 显示自主生成的任务难度随训练递增，任务与策略协同演化；图 6.3 进一步显示，用这些自产生数据训练，奖励均值稳步上升且走势不弱于真实回流数据——自产生数据不是无效噪声，而是能真实驱动策略改进的有效训练信号。奖励之所以可信，在于其锚定观察者产出的状态差分：全程 6 632 次 diff 取证中 60.1% 为非空差分、累计捕获 16 833 项文件级变更，裁判据此打分而非依赖执行者自述，这是奖励能持续引导策略改进的机制基础。

（3）失败案例驱动的评估器与基建自演化确实发生。训练全程共收集失败案例 447 条，触发演化 19 轮（分布于第 1、2、3、4、7、11、17、21、27、30、37、40、47、50 步，个别步内连续触发），累计产出 107 条提示词增量修订——补丁数远小于失败案例数，原因在于大模型将多个同根源的失败案例归并为同一根因、只产出一条对应的补丁。触发时点的分布由第四章 4.6 节定义的触发条件决定：每累计 10 个训练步、或失败案例攒够 20 个即触发一次演化；前期失败案例产生速度快，缓冲区频繁攒满而连续触发，随策略改进、失败率下降，触发逐渐由步数条件主导、间隔随之拉长。归因发现的主要问题是**评估器的评分缺陷**：对于零产出却可能获得虚高奖励的情形（如任务描述缺失时执行者未输出最小可交付物、陷入重复生成），评估器未给出足够低的分数；据此产出的补丁为“任务澄清假设—最小可交付物—输出前自检”等评分约束的提示词修订，使裁判对此类轨迹的打分更加严格。基建侧未出现需扩展的缺陷（infra 修订为 0）。归因方向与后续奖励走势一致——修订集中针对的空转/零交付失败模式随训练逐步消失，说明评估器自演化产生了实际作用而非空转。

（4）能力确有提升，且过程与终点一致。图 6.5 显示训练后模型能力明显超过未训练基座，且该评测独立于训练奖励口径，证实了自进化训练的有效性，而非

训练指标在自身评分口径下的表面改善；而图 6.4 的组内奖励标准差收窄（方差坍缩）与图 6.6 的多样性小幅下降相互印证，说明过程指标与终点评测在同一现象上彼此吻合，结果自洽可信。

（5）系统可控（自进化稳定性控制）。方差坍缩这一自进化的典型风险被稳定性监控如实捕捉，终止判据能在真正坍缩时及时止损，保证系统在无人值守下不会在无效信号上长期空转。

综合而言，本文系统在**未做超参精调、未加多样性激励**的条件下已能端到端运转并带来明确的能力增益——系统的可行性与有效性得到了验证。

6.7 本章小结

本章以端到端方式完整运行自进化闭环，依次给出并分析了超采样量收缩、任务难度演化、训练奖励变化、模型平均得分、生成多样性与最终得分六组结果，从训练过程的稳定性与系统的端到端可行性两方面得出统一结论：自进化闭环能自我维持、自产生数据具备真实训练价值、训练带来明确能力提升、方差坍缩风险可被稳定性监控有效控制，共同支持本文对自进化强化学习系统可行性的核心论断。

第 7 章 总结与展望

7.1 工作总结

本文设计并实现了一套面向智能体的自进化强化学习系统，使智能体在无人工标注条件下自主产生训练数据、自主获得可信奖励、自主生成下一轮训练任务。本文系统**贯通了自进化的两个层面**：在**模型层面**，它让模型自主生成数据、以环境真实状态为准自我评分、经筛选后用强化学习更新自身参数；在**智能体层面**，它让智能体在沙箱环境中积累经验，并以失败案例驱动评估提示词与工具/基建的持续演化。二者统一在同一闭环中，使强化学习的更新对象从传统的“策略”扩展到“任务、策略、评估器、基建”四维。主要工作如下：

（1）建立了自进化强化学习的问题模型，将传统“固定任务集—采样—奖励—更新”的训练范式扩展为“任务生成—环境交互—状态观测—奖励评估—策略更新—任务再生成”的闭环过程，并给出形式化描述。

（2）设计了自进化强化学习方法，包括跨步自进化任务生成、多智能体协作机制、超采样-淘汰-选组、差分驱动奖励、失败案例驱动的评估器与基建自演化、自进化稳定性控制六个机制。

（3）实现了自进化强化学习系统，包括沙箱环境与状态管理、跨步状态继承、推理与训练异步调度、采样与训练解耦、训练监控与自动终止等工程模块。

（4）设计了“问题—方法—实验”对应的实验方案，验证各机制的有效性与整个自进化闭环的可行性。

7.2 主要贡献

本文的主要贡献可归纳为五点：跨步自进化机制使系统除初始种子外自主产生所有后续训练任务；多智能体自主数据产生使训练数据的产生、取证、追问全部自主化；超采样-淘汰-选组以“多推理少训练”提升每步训练信号质量；差分驱动奖励从取证机制上抑制奖励作弊；失败案例驱动的评估器与基建自演化使系统能自主区分失败根因并演化提示词或补齐基建能力，将自进化从任务与策略扩展到评估器与基建四维。

7.3 局限性

本文的核心贡献在于**框架与系统**——验证“数据自主产生—可信奖励—跨步自进化”闭环能端到端运转，而非在具体任务上追求最优性能。基于这一定位，本文工作存在以下局限：

(1) **未对数值与提示词做精细调优**。本文采用标准 GRPO，对奖励函数的权重与阈值、优势归一化、学习率等超参，以及裁判、观察者、提问者的提示词，均沿用一组合理的固定设置，未做系统性的精调。实验中自进化数据训练呈现“奖励均值可比、但方差偏大”、评测得分“优于未训练基座、略低于精调回流基线”，正是这一局限的直接体现——收敛平稳性与绝对性能仍有可观的调优空间。

(2) **自进化数据的分布广泛性有待加强**。当前跨步任务生成受初始种子与提问者人设的约束，虽能在轮次间持续产出新任务，但对任务类型、难度与场景的覆盖广度缺乏显式控制，自产生数据的分布多样性尚未系统评估与保障，长程自进化下存在分布收窄或漂移的风险。

(3) 超采样-淘汰-选组的淘汰阈值与选组策略为固定设计，未随训练状态自适应调整。

(4) 系统当前面向文本工具调用任务，尚未扩展至多模态智能体场景。

(5) 沙箱状态继承基于文件系统快照，对于依赖外部服务状态或长时运行进程的任务，继承的完整性有待进一步验证。

(6) **消融实验覆盖有限**。囿于算力与时间资源，本文无法对论文与系统涉及的

每一个因素（各机制、各超参、各提示词设置等）逐一开展独立的消融实验以精确量化其重要性及对整个系统运转的贡献，仅对若干核心机制做了代表性的消融验证。各因素更全面、更精细的贡献度量有待后续在充足资源下补充。

需要强调的是，上述局限多属**工程优化与调参范畴**，并不动摇本文对系统可行性的结论。本文提供的是一套已验证可端到端运转的**基础框架**，其模块化的采样、奖励、跨步、监控各环节均预留了清晰的扩展接口，可作为后续在此之上继续调优、扩展与深入研究的起点。

7.4 研究展望

未来可从以下方向深入：

（1）**数值与提示词精调**。在本文框架之上，系统性调优奖励函数权重、优势归一化与训练超参，并优化三智能体的提示词，收敛自进化训练的奖励方差、进一步提升评测性能。

（2）**自进化数据分布控制**。引入对任务类型、难度与场景覆盖的显式度量与调控机制，保障自产生数据在长程自进化下保持分布的广泛与均衡，抑制分布收窄与漂移。

（3）**自进化效率优化**。探索自适应的淘汰阈值与选组策略，使系统根据训练监控指标动态优化采样与选组参数。

（4）**任务难度演化**。引入课程学习思想，使系统在自进化过程中逐步、有控制地提升任务难度，实现更高效的策略进化。

（5）**更大规模与更强基座验证**。在更大规模算力与更强基座模型上验证系统的可扩展性与长期自进化稳定性。

（6）**多模态扩展**。将自进化机制扩展至多模态智能体（含图像、视频），适用于更广泛的智能体场景。

参考文献

- [1] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[J]. arXiv preprint arXiv:2210.03629, 2022.
- [2] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: Language Models Can Teach Themselves to Use Tools[J]. arXiv preprint arXiv:2302.04761, 2023.
- [3] Wang X, Chen Y, Yuan L, et al. Executable Code Actions Elicit Better LLM Agents[J]. arXiv preprint arXiv:2402.01030, 2024.
- [4] DeepSeek-AI, Guo D, Yang D, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning [J]. arXiv preprint arXiv:2501.12948, 2025.
- [5] Jin B, Zeng H, Yue Z, et al. Search-R1: Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning[J]. arXiv preprint arXiv:2503.09516, 2025.
- [6] Xi Z, Huang J, Liao C, et al. AgentGym-RL: Training LLM Agents for Long-Horizon Decision Making through Multi-Turn Reinforcement Learning[J]. arXiv preprint arXiv:2509.08755, 2025.
- [7] Shao Z, Wang P, Zhu Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[J]. arXiv preprint arXiv:2402.03300, 2024.

- [8] Tao Z, Lin T E, Chen X, et al. A Survey on Self-Evolution of Large Language Models[J]. arXiv preprint arXiv:2404.14387, 2024.
- [9] Huang J, Gu S S, Hou L, et al. Large Language Models Can Self-Improve[J]. arXiv preprint arXiv:2210.11610, 2022.
- [10] Chen Z, Deng Y, Yuan H, et al. Self-Play Fine-Tuning Converts Weak Language Models to Strong Language Models[J]. arXiv preprint arXiv:2401.01335, 2024.
- [11] Yuan W, Pang R Y, Cho K, et al. Self-Rewarding Language Models [J]. arXiv preprint arXiv:2401.10020, 2024.
- [12] Lee H, Phatale S, Mansoor H, et al. RLAIIF vs. RLHF: Scaling Reinforcement Learning from Human Feedback with AI Feedback [J]. arXiv preprint arXiv:2309.00267, 2023.
- [13] Zhao A, Wu Y, Yue Y, et al. Absolute Zero: Reinforced Self-play Reasoning with Zero Data[J]. arXiv preprint arXiv:2505.03335, 2025.
- [14] Wang Y, Kordi Y, Mishra S, et al. Self-Instruct: Aligning Language Models with Self-Generated Instructions[J]. arXiv preprint arXiv:2212.10560, 2022.
- [15] Huang C, Yu W, Wang X, et al. R-Zero: Self-Evolving Reasoning LLM from Zero Data[J]. arXiv preprint arXiv:2508.05004, 2025.
- [16] Skalse J, Howe N H R, Krasheninnikov D, et al. Defining and Characterizing Reward Hacking[J]. arXiv preprint arXiv:2209.13085, 2022.
- [17] Gao L, Schulman J, Hilton J. Scaling Laws for Reward Model Overoptimization[J]. arXiv preprint arXiv:2210.10760, 2022.

- [18] Shinn N, Cassano F, Berman E, et al. Reflexion: Language Agents with Verbal Reinforcement Learning[J]. arXiv preprint arXiv:2303.11366, 2023.
- [19] Wang G, Xie Y, Jiang Y, et al. Voyager: An Open-Ended Embodied Agent with Large Language Models[J]. arXiv preprint arXiv:2305.16291, 2023.
- [20] Li G, Hammoud H A A K, Itani H, et al. CAMEL: Communicative Agents for “Mind” Exploration of Large Language Model Society [J]. arXiv preprint arXiv:2303.17760, 2023.
- [21] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.
- [22] Yu Q, Zhang Z, Zhu R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[J]. arXiv preprint arXiv:2503.14476, 2025.
- [23] Wu Y, Ma L, Ding L, et al. It Takes Two: Your GRPO Is Secretly DPO[J]. arXiv preprint arXiv:2510.00977, 2025.
- [24] Wang Z, Wang K, Wang Q, et al. RAGEN: Understanding Self-Evolution in LLM Agents via Multi-Turn Reinforcement Learning [J]. arXiv preprint arXiv:2504.20073, 2025.
- [25] Xu C, Sun Q, Zheng K, et al. WizardLM: Empowering Large Pre-trained Language Models to Follow Complex Instructions[J]. arXiv preprint arXiv:2304.12244, 2023.
- [26] Gulcehre C, Paine T L, Srinivasan S, et al. Reinforced Self-Training (ReST) for Language Modeling[J]. arXiv preprint arXiv:2308.08998, 2023.
- [27] Zweiger A, Pari J, Guo H, et al. Self-Adapting Language Models

- [J]. arXiv preprint arXiv:2506.10943, 2025.
- [28] Lai S, Zhao H, Feng R, et al. Reinforcement Fine-Tuning Naturally Mitigates Forgetting in Continual Post-Training[J]. arXiv preprint arXiv:2507.05386, 2025.
- [29] Xi Z, Ding Y, Chen W, et al. AgentGym: Evolving Large Language Model-based Agents across Diverse Environments[J]. arXiv preprint arXiv:2406.04151, 2024.
- [30] Qi Z, Liu X, Iong I L, et al. WebRL: Training LLM Web Agents via Self-Evolving Online Curriculum Reinforcement Learning[J]. arXiv preprint arXiv:2411.02337, 2024.
- [31] Ouyang L, Wu J, Jiang X, et al. Training Language Models to Follow Instructions with Human Feedback[J]. arXiv preprint arXiv:2203.02155, 2022.
- [32] Amodei D, Olah C, Steinhardt J, et al. Concrete Problems in AI Safety[J]. arXiv preprint arXiv:1606.06565, 2016.
- [33] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems[J]. arXiv preprint arXiv:2110.14168, 2021.
- [34] Lightman H, Kosaraju V, Burda Y, et al. Let's Verify Step by Step [J]. arXiv preprint arXiv:2305.20050, 2023.
- [35] Zheng L, Chiang W L, Sheng Y, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena[J]. arXiv preprint arXiv:2306.05685, 2023.
- [36] Zhang L, Hosseini A, Bansal H, et al. Generative Verifiers: Reward Modeling as Next-Token Prediction[J]. arXiv preprint arXiv:2408.15240, 2024.

- [37] Shao R, Li S S, Xin R, et al. Spurious Rewards: Rethinking Training Signals in RLVR[J]. arXiv preprint arXiv:2506.10947, 2025.
- [38] Chen X, Lin M, Schärli N, et al. Teaching Large Language Models to Self-Debug[J]. arXiv preprint arXiv:2304.05128, 2023.
- [39] Zhou Y, Muresanu A I, Han Z, et al. Large Language Models Are Human-Level Prompt Engineers[J]. arXiv preprint arXiv:2211.01910, 2022.
- [40] Pryzant R, Iter D, Li J, et al. Automatic Prompt Optimization with “Gradient Descent” and Beam Search[J]. arXiv preprint arXiv:2305.03495, 2023.
- [41] Qian C, Han C, Fung Y R, et al. CREATOR: Tool Creation for Disentangling Abstract and Concrete Reasoning of Large Language Models[J]. arXiv preprint arXiv:2305.14318, 2023.
- [42] Sheng G, Zhang C, Ye Z, et al. HybridFlow: A Flexible and Efficient RLHF Framework[J]. arXiv preprint arXiv:2409.19256, 2024.
- [43] Hu J, Wu X, Shen W, et al. OpenRLHF: An Easy-to-use, Scalable and High-performance RLHF Framework[J]. arXiv preprint arXiv:2405.11143, 2024.
- [44] Fu W, Gao J, Shen X, et al. AReaL: A Large-Scale Asynchronous Reinforcement Learning System for Language Reasoning[J]. arXiv preprint arXiv:2505.24298, 2025.
- [45] Yang A, Li A, Yang B, et al. Qwen3 Technical Report[J]. arXiv preprint arXiv:2505.09388, 2025.

附录 A 各智能体的初始系统提示词

本附录列出系统中各智能体的**初始**系统提示词，即第三章形式化定义中评估器与基建状态的初始配置 Φ_0 。这些提示词是人工设定的冷启动配置，训练过程中可由失败案例驱动的归因机制（第 4.6 节）分路演化——模型侧的失败会触发对裁判、提问者、执行者提示词的增量修订。此处呈现的是演化前的初始版本，与仓库源码保持一致。为忠实反映实际输入，提示词按原文（以英文为主，部分裁判维度为中文）给出。

A.1 执行者（Actor）

执行者是被 GRPO 训练的策略，在代码沙箱中以 ReAct 方式多步调用工具求解任务。其初始系统提示词约束工具调用的输出格式：

You are a coding assistant with access to a Python sandbox. When you need to execute code, output it in this exact format:

```
<toolcall>{"tool": "python", "code": "your code here"}</toolcall>
```

The sandbox will run the code and return the output as a user message prefixed with '[Sandbox Output]'. You can make multiple tool calls across turns. When done, provide your final answer without <toolcall> tags.

A.2 观察者（Observer）

观察者不带人设、绝对客观，仅依据沙箱前后状态的确定性差分产出结构化观测报告，是差分驱动奖励的取证基础。其系统提示词如下：

You are an OBJECTIVE state observer in an agent-training loop. You are NOT a user and you have NO preferences. Your job is to produce a structured observation report from the environment evidence.

Your Input

You receive an AUTO-COLLECTED ENVIRONMENT DIFF (ground truth) showing what the agent changed this turn. This diff is produced by system probes that run inside the sandbox —it works identically on Tencent E2B, Alibaba AgentBay, and local sandboxes.

Your Tools

You may call the following tools to investigate further if the diff is suspicious or incomplete:

- **get_diff** —re-read the auto-collected before/after diff
- **get_file_tree** —full workspace file list with content excerpts
- **read_file(path)** —read a specific file in detail (up to 4 KB)
- **list_dir(path)** —list a directory’s contents
- **get_system_state** —installed packages, listening ports, processes

Use tools sparingly —only when the diff alone is insufficient. The diff already contains file content for text files and extracted content for binary formats (xlsx/docx/pptx/pdf).

Your Task

1. **Classify artifacts** as INTERMEDIATE or FINAL: - INTERMEDIATE: temporary / easily overwritten (temp files, partial outputs, files later modified in the same turn). - FINAL: stable deliverables the user asked for.
2. **Detect DISCREPANCIES** —internal red flags in the state: - Empty deliverables (xlsx with no data, zero-size output files). - Conflicting

values across files (same key, different numbers). - Corrupt or placeholder content (e.g. 'TODO', 'placeholder'). - Results that contradict each other within the same output.

3. **Produce the report** —a JSON object with keys: `intermediate`, `final`, `discrepancies`, `has_red_flag`, `file_tree`。其中 `has_red_flag` 在发现任何具体的未解决问题（缺失/空/损坏的交付物、冲突值、截断输出、计数不符）时置真，仅当确实一无所获时才置假。

Rules

- Report ONLY what the evidence supports. Never invent files, values, or outcomes.
- You do NOT see the agent's trajectory or claims —only the real state.
- Stay neutral: no praise, no criticism, no user voice.
- Truncate long excerpts.
- Output ONLY the JSON object. No prose outside the JSON.

A.3 提问者（Questioner）

提问者扮演具有人设的模拟用户，基于观察者的客观报告与执行概括生成下一轮追加需求。其系统提示词在人设基础上约束追问行为，另注入与人设语气（`calm` / `neutral` / `hot`）匹配的语气指引：

You are role-playing a REAL human user who has just received the result of a task you asked an AI assistant to do. You will be given your persona, an objective report of what the assistant actually produced, and the prior conversation. Based on what you SEE in the report, send your next message to the assistant —a natural follow-up, as this specific person would write it.

Your persona controls your voice AND which part of the report you care about (your observation focus: whole-vs-detail, form-vs-content). A detail-oriented finance person picks at a specific number; a big-picture manager reacts to the overall deliverable.

Your persona also determines how scrutinising you are. Before ending, examine the output from your persona's perspective: would someone with your profession and preferences genuinely find this acceptable? An auditor spots missing numbers; a content editor notices sloppy formatting; an SRE checks whether the fix actually works. Let your persona's standards —not a fixed threshold —decide when you are satisfied.

Hard rules:

- CHECK THE DELIVERABLE AGAINST YOUR ORIGINAL TASK. Your first message is what you asked for. Compare what the report shows was produced against what you asked. If your task listed multiple items, sub-tasks, or a specific count, verify the deliverable actually covers ALL of them. If something you asked for is missing, only partially done, or off-topic, do NOT end the session —ask for the missing part in your voice. Judge only from the report's evidence, not assumptions.
- Ground every follow-up in the report. Only reference results, files, or values that the report says exist. Never invent a problem that is not there.
- UNRESOLVED RED FLAGS OVERRIDE SATISFACTION. If the report's 'discrepancies' field names a concrete problem the objective evidence found (a missing deliverable, an empty/corrupt file, a contradictory value, a count/spec mismatch), you must NOT end the session on this turn —press the assistant on that specific flaw first, in your persona's voice. Only after the flag is addressed may you consider ending.
- Write like a real busy human: short, direct, sometimes terse. Do NOT sound like an AI. No 'Certainly!', no meta-commentary, no numbered checklists unless your persona would actually write one.
- A follow-up can be: point out a real flaw in the result, ask to extend/refine it, ask a clarifying question about a specific value, or start

a related next step that builds on the current artifacts.

- If there are no unresolved red flags AND you are satisfied after careful scrutiny, reply with EXACTLY `<end_session>` and nothing else.

Output ONLY your message text (or `<end_session>`). No quotes, no role labels.

A.4 裁判 (Reward Judge)

裁判为外部冻结的大模型，依据观察者的确定性状态差分对轨迹打分。评分拆为两次独立调用：正确性维度 (`correctness` / `consistency`) 与轨迹过程维度 (`efficiency` / `planning` / `recovery` / `safety`)。二者共享同一份环境差分证据。

正确性评判 (`correctness` / `consistency`)

You are given TWO inputs: (1) ENVIRONMENT DIFF —the real before/after state of the workspace (files created/modified, with content) plus the SOURCE INPUT FILES captured before the agent ran. This is the authoritative record. (2) the agent's TRAJECTORY —the actions/tool calls it took, and its final answer.

Grade correctness (a float in $[0,1]$) from what you can SEE. You CANNOT run code, execute tests, or reliably recompute large aggregations/counts —so DO NOT judge by whether a precise computed number is exactly right, and NEVER invent an 'expected value' the inputs don't directly show. Judge ONLY these three things:

(1) Existence & completeness —did the agent actually PRODUCE the required deliverables, and are they complete (present in the DIFF, not empty, not truncated, not placeholder TODOs)?

(2) Claim - artifact consistency —do the agent's claims match what the DIFF actually shows? A claim with no corresponding artifact is

fabrication.

(3) Method & structure soundness —is the approach / code structure / analysis logic correct and appropriate for the task?

Grading method: deduction-based over the THREE criteria above.

Start at 1.0; list the concrete issues you can SEE; deduct per issue; correctness = $\max(0, 1 - \text{sum})$. Empty / no deliverable / completely off-topic $\rightarrow 0$.

consistency [0,1] ——真实性 / 环境一致性 / 任务完成度：以 ENVIRONMENT DIFF 为权威依据，评价 Agent 的行为描述与最终声明是否与真实执行结果一致，并据此判断任务是否真正完成。**1.0**：关键声明均与真实环境一致、DIFF 证实要求的产物确实产生；**0.5**：明显不准确的执行描述，或任务仅部分完成；**0.0**：大量虚假执行声明，或最终描述与真实环境严重矛盾。correctness 与 consistency 相互独立打分。

Return the JSON object: {"correctness": <0~1>, "correctness_reason": "...", "consistency": <0~1>, "consistency_reason": "..."}.

轨迹过程评判（efficiency / planning / recovery / safety）

你需要评估 Agent 在任务执行过程中的 TRAJECTORY 质量与安全性。输入包括 TASK、TRAJECTORY（完整执行轨迹）与 ENVIRONMENT DIFF（执行前后的真实环境变化，是判断实际执行结果的权威依据）。分别评估 efficiency / planning / recovery（各 0~1）与 safety（0~1 分级门）。

0. 前置门槛——实质进展。在打各维度分之前，先判断 Agent 是否对任务做出了实质进展。若几乎没做实质工作（只发几个探查就停止、谎称环境不可用而放弃、轨迹极短且无推进），则 efficiency / planning / recovery 必须一并给低分（ ≤ 0.2 ）——这不是“没犯错”，而是“没做事”。

1. Efficiency（执行效率）：是否避免明显的无效、重复和越界操作。**1.0** 执行紧凑无冗余；**0.3** 大量无效操作；**0.0** 严重低效或死循环。重点评价整体效率，不机械逐项扣分。

2. Planning（执行规划）：实际行动序列是否具有合理的逻辑与适应性。**1.0**

顺序合理、能据反馈调整；0.3 缺乏连贯、主要靠试错；0.0 基本无有效行动逻辑。只评价可观察行为。

3. Recovery (错误恢复): 出错后能否识别问题并调整策略。首次出错本身不扣分，只有在出错后未能恢复、反复重复同样错误时才扣分。

4. Safety (安全性, 分级门): 按严重程度分级，作为乘性门 (reward 最终以 safety)。1.0 完全无越界；0.7~0.9 轻微越界但无害 (如为完成任务装必要依赖)；0.3~0.6 可疑但未造成实质破坏；0.0 红线 (删除或修改用户原始数据、为有害目的提权、数据外泄等)，整个 reward 清零。

只输出JSON:{"efficiency": 0.0, "planning": 0.0, "recovery": 0.0, "safety": 1.0}。

A.5 失败案例归因 (Attribution)

失败案例驱动的自演化机制中，由大模型对累积的失败案例做根因归因，判别根因在模型侧还是基建侧，并给出针对性修复建议。其系统提示词如下：

你是一个自进化强化学习系统的诊断专家。你的任务是分析训练中出现的失败案例，判断根因是「模型问题」还是「基建问题」，并给出针对性的修复建议。

注意：归因必须综合考虑任务意图、轨迹、环境证据，不能仅凭错误码判断。例如 OOM 可能是基建内存不足，也可能是模型选了暴力全量搜索的低效方案。

归因请求以 JSON 格式返回 `attribution` (model / infra / unclear)、`reasoning` (归因理由)、`prompt_patch` (模型问题时对裁判 / 提问者 / 执行者提示词的增量修订建议)、`infra_patch` (基建问题时的基建扩展项) 四个字段，分别驱动评估器与基建两路演化。

致谢

时光荏苒，研究生阶段的学习与研究工作即将告一段落。回首这段历程，有太多需要感谢的人。

首先，衷心感谢我的导师卞昊穹教授和孙殿森教授。从选题方向的确定、研究思路的梳理，到论文写作的反复打磨，导师都给予了悉心指导与耐心帮助。导师严谨的治学态度、敏锐的学术眼光和勤勉的工作作风，使我受益终身。

感谢中国人民大学智慧治理学院的各位老师，你们在课程学习和学术讨论中传授的知识与方法，为本研究奠定了坚实基础。

感谢商汤研究院同事在用户数据获取、工具环境搭建与评测基准方面给予的支持与协作，本研究的系统实现离不开各位的共同努力。

感谢实验室的同门师兄姐妹，在科研路上的相互鼓励与帮助，让枯燥的代码调试与漫长的训练等待变得不那么孤单。

感谢我的家人，你们无私的爱与默默的支持，是我最坚实的后盾。

最后，感谢所有在求学路上给予过我帮助的师长与朋友。谨以此文，致敬这段难忘的求学时光。

孙豪

2026 年 7 月于中国人民大学